

Università della Calabria

Dipartimento di Ingegneria Informatica,
Modellistica, Elettronica e Sistemistica

Corso di Laurea Magistrale in Ingegneria Informatica
Indirizzo Intelligenza Artificiale

GRAnD-NL

Anomaly Detection Non Supervisionata tramite Negative Learning e Stabilizzazione Dinamica

Report di Machine Learning e Deep Learning

Studente:

Davide Cinelli
Matricola: 269491

Anno Accademico 2025/2026

Indice

1 Introduzione **1**

2 Definizione del problema e background teorico **3**

2.1 Anomaly Detection non supervisionata 3

2.2 Metodi basati sulla ricostruzione 3

2.3 Autoencoder generativi 4

2.3.1 Variational Autoencoder 5

2.3.2 Normalizing Flows 5

2.4 Extreme Value Theory per Anomaly Detection 6

2.4.1 Peaks-Over-Threshold 6

2.5 Robustezza e contaminazione nel training 7

2.5.1 Negative Learning come strategia alternativa 7

2.6 Stato dell'arte nella anomaly detection robusta 8

3 Il framework GRAnD **9**

3.1 Panoramica generale 9

3.2 Modello generativo e score di anomalia 9

3.3 Strategia di rejection robusta basata su EVT 10

3.3.1 Definizione delle soglie u e t_q 10

3.3.2 Suddivisione dei dati in L, U e S 10

3.4 Funzione di loss di GRAnD 11

3.4.1 Loss sui campioni nominali 11

3.4.2 Loss sui campioni anomali 11

3.4.3 Gestione dei campioni incerti 12

3.5 Obiettivo complessivo e algoritmo di training 12

4 Dataset e setup sperimentale **13**

4.1 Dataset NSL-KDD 13

4.1.1 Preprocessing e feature engineering 13

4.1.2 Strategia di contaminazione 13

4.2 Protocollo sperimentale 14

4.3 Dettagli computazionali 14

4.4 Considerazioni preliminari 15

5 Proposte di miglioramento del framework GRAnD **16**
5.1 Stabilizzazione del training dinamico . . . 16
5.1.1 Warmup e ramp sulle componenti della funzione obiettivo . . . 16
5.1.2 Loss a margine con funzione liscia . . . 17
5.1.3 Strategie di thresholding EVT . . . 18
5.1.4 Curriculum learning sulle soglie EVT . . . 19
5.1.5 Discussione sulla stabilità complessiva . . . 19
5.2 Integrazione del negative learning nel framework GRAnD . . . 20
5.2.1 Motivazione dell'integrazione . . . 20
5.2.2 Applicazione selettiva sugli insiemi S e U . . . 20
5.2.3 Funzioni distruttive dell'input . . . 21
5.2.4 Scheduling del negative learning e interazione con la loss GRAnD . . . 21
5.2.5 Considerazioni finali . . . 21
5.3 Early stopping basato su convergenza strutturale . . . 22
5.3.1 Grandezze monitorate . . . 22
5.3.2 Misure di stabilità su finestra temporale . . . 22
5.3.3 Criterio di arresto . . . 23
5.3.4 Interpretazione come convergenza strutturale . . . 23
5.3.5 Vantaggi del criterio proposto . . . 23
5.4 Explainability by design . . . 23
5.4.1 Decomposizione strutturale dello score di anomalia . . . 24
5.4.2 Explainability basata sull'errore di ricostruzione . . . 24
5.4.3 Explainability gradient-based sullo score energetico . . . 24
5.4.4 Selezione adattiva della modalità esplicativa . . . 25
5.4.5 Vantaggi dell'approccio by design . . . 25
5.5 Estensione architetturale del framework: GRAnD-ResMLP . . . 25
5.5.1 Motivazione architetturale . . . 26
5.5.2 Architettura ResMLP per GRAnD . . . 26
5.5.3 Integrazione con il framework GRAnD . . . 26
5.5.4 Considerazioni su capacità e costo computazionale . . . 27
5.6 Pseudocodice del framework GRAnD esteso . . . 27

6 Valutazione sperimentale e studi di ablation **29**
6.1 Introduzione . . . 29
6.2 Baseline: GRAnD originale . . . 29
6.2.1 Replicazione dei risultati del paper . . . 29
6.2.2 Analisi del comportamento durante il training . . . 30
6.2.3 Prestazioni di detection al variare della contaminazione . . . 30
6.3 Ablation su singoli meccanismi di robustezza . . . 31
6.3.1 Early stopping strutturale . . . 31
6.3.2 Thresholding con cap empirico (POT-cap) . . . 33
6.3.3 Negative learning (AESAD) . . . 34
6.4 Combinazione dei meccanismi di robustezza . . . 35

6.5 Explainability: analisi qualitativa 36
6.6 Discussione complessiva dei risultati 37

7 Conclusioni e sviluppi futuri **38**

Capitolo 1

Introduzione

La rilevazione di anomalie (*Anomaly Detection, AD*) rappresenta un problema fondamentale in numerosi ambiti applicativi, tra cui la sicurezza informatica, il monitoraggio di reti di comunicazione, la manutenzione predittiva e l'analisi di sistemi complessi. In particolare, nel contesto della *network intrusion detection*, l'obiettivo è individuare comportamenti anomali o potenzialmente malevoli all'interno di grandi volumi di traffico di rete, spesso in assenza di etichette affidabili e aggiornate.

Nella maggior parte degli scenari reali, l'utilizzo di tecniche supervisionate risulta impraticabile a causa della scarsità di dati etichettati, della rapida evoluzione delle tipologie di attacco e dell'elevato costo associato alla creazione di dataset annotati manualmente. Per questo motivo, la anomaly detection non supervisionata ha assunto un ruolo centrale, ponendosi come alternativa naturale ai sistemi di rilevazione basati su firme o regole statiche.

Tra gli approcci non supervisionati, i metodi basati sulla ricostruzione, in particolare gli autoencoder e le loro estensioni generative, hanno ottenuto risultati significativi. L'ipotesi alla base di tali metodi è che un modello addestrato prevalentemente su dati nominali sia in grado di ricostruire accuratamente i campioni normali, mentre produca errori di ricostruzione elevati in presenza di anomalie. Tuttavia, questa assunzione viene frequentemente violata nei contesti reali, nei quali il dataset di training risulta contaminato da una frazione ignota di campioni anomali. In tali condizioni, modelli standard come autoencoder classici o variational autoencoder tendono a incorporare anche i pattern anomali nella rappresentazione appresa, degradando significativamente le prestazioni di rilevazione.

La presenza di contaminazione nel training set costituisce quindi una delle principali criticità della anomaly detection non supervisionata. Molti metodi robusti proposti in letteratura introducono ipotesi esplicite sulla distribuzione delle anomalie o richiedono una stima preventiva della loro percentuale, rendendo il modello sensibile alla scelta degli iperparametri e difficile da applicare in scenari reali. In questo contesto, risulta particolarmente rilevante lo studio di approcci capaci di adattarsi dinamicamente alla presenza di outlier, senza fare assunzioni forti sulla loro natura o frequenza.

Il framework GRAnD (*Generative Robust Anomaly Detection*) si inserisce in questa linea di ricerca, proponendo una strategia di apprendimento robusta che combina modelli generativi basati su autoencoder con strumenti di *Extreme Value Theory* (EVT). L'idea centrale di GRAnD consiste nell'alternare fasi di apprendimento della distribuzione nominale a una procedura di

filtraggio degli outlier basata sull'analisi delle code estreme della distribuzione degli score di anomalia. In questo modo, il modello non si limita a ignorare i campioni anomali presenti nel training set, ma li utilizza attivamente per migliorare la separazione tra comportamenti normali e anomali.

Accanto a strategie basate sul filtraggio esplicito degli outlier, recenti lavori hanno esplorato approcci alternativi per affrontare la contaminazione nel training set attraverso meccanismi di *negative learning*. In particolare, il framework AESAD propone di sfruttare campioni ritenuti anomali per forzare il modello a ricostruirli intenzionalmente in modo scorretto, introducendo una dinamica di repulsione tra regioni nominali e anomale nello spazio latente. Sebbene AESAD condivida con GRAnD l'obiettivo di contrastare la contaminazione nei dati di addestramento, esso si fonda su principi concettualmente distinti, rendendo interessante un'analisi comparativa e lo studio di una possibile integrazione all'interno del framework GRAnD.

Questo lavoro si propone di analizzare in profondità il framework GRAnD, replicandone i risultati principali sul dataset NSL-KDD e fornendo una disamina dettagliata del comportamento dinamico del modello durante il training. Oltre alla replicazione del metodo originale, viene condotta un'analisi empirica delle soglie basate su EVT, della suddivisione dinamica dei dati nei sottoinsiemi nominali, incerti e anomali, e della stabilità del processo di apprendimento in presenza di contaminazione.

Sulla base delle osservazioni sperimentali emerse, il lavoro introduce e valuta alcuni meccanismi di robustezza volti a migliorare l'efficienza e la stabilità del framework, tra cui un criterio di early stopping basato su segnali interni al modello, una variante del thresholding EVT con cap empirico e l'integrazione di una componente di negative learning ispirata ad AESAD. L'obiettivo non è quello di massimizzare ulteriormente le metriche di prestazione, bensì di rafforzare la coerenza metodologica, la stabilità numerica e la riproducibilità del framework in scenari realistici di anomaly detection non supervisionata.

La struttura del documento è la seguente. Nel Capitolo 2 viene introdotto il background teorico necessario, comprendente la definizione formale del task di anomaly detection, i modelli autoencoder generativi e i fondamenti della Extreme Value Theory. Il Capitolo 3 descrive in dettaglio il framework GRAnD, illustrandone la funzione obiettivo, il meccanismo di thresholding e il protocollo di addestramento. Nel Capitolo 4 viene presentato il dataset utilizzato e il setup sperimentale. Il Capitolo 5 discute le estensioni e i meccanismi di robustezza proposti. Nel Capitolo 6 viene riportata una valutazione sperimentale approfondita, strutturata come uno studio di ablation. Infine, il Capitolo 7 riassume le conclusioni e discute possibili sviluppi futuri.

Capitolo 2

Definizione del problema e background teorico

2.1 Anomaly Detection non supervisionata

La Anomaly Detection (AD) non supervisionata consiste nell'identificazione di osservazioni che deviano in modo significativo dal comportamento considerato normale, in assenza di etichette durante la fase di addestramento. Formalmente, dato un insieme di osservazioni $\mathcal{X} = \{\boldsymbol{x}_i\}_{i=1}^{N} \subset \mathbb{R}^d$ campionate da una distribuzione ignota $p(\boldsymbol{x})$, l'obiettivo è apprendere un modello del comportamento nominale che consenta di assegnare a ogni campione uno *score di anomalia* $s(\boldsymbol{x})$.

Nel paradigma non supervisionato, si assume che la maggior parte dei campioni nel dataset di training sia nominale, mentre le anomalie costituiscano una frazione minoritaria. Una volta definito uno score $s(\boldsymbol{x})$, il problema della rilevazione delle anomalie si riduce alla definizione di una soglia τ tale che:

$$\boldsymbol{x} \text{ è anomalo} \iff s(\boldsymbol{x}) > \tau. \tag{2.1}$$

La scelta dello score e della soglia rappresenta un aspetto cruciale del problema. In particolare, in scenari reali la distribuzione di $s(x)$ è spesso sconosciuta e fortemente sbilanciata, rendendo difficoltosa l'adozione di soglie fisse o parametriche. Questo aspetto motiva l'interesse verso approcci adattivi e robusti, capaci di modellare esplicitamente il comportamento degli score estremi. Nel seguito ci concentreremo sugli approcci basati sulla ricostruzione e su modelli generativi, in quanto essi consentono di definire uno score di anomalia nello spazio originale dei dati e di introdurre strategie di robustezza direttamente sulla funzione obiettivo, aspetti centrali per il framework GRAnD.

2.2 Metodi basati sulla ricostruzione

Tra le famiglie di approcci più diffuse per la anomaly detection non supervisionata rientrano i metodi basati sulla ricostruzione. Questi approcci assumono che sia possibile apprendere una rappresentazione compatta del comportamento nominale, tale per cui i campioni normali vengano ricostruiti accuratamente, mentre le anomalie producano errori di ricostruzione elevati.

Un Autoencoder (AE) è una rete neurale composta da due moduli: un encoder $\psi(\cdot)$ e un decoder $\phi(\cdot)$. Dato un input $\boldsymbol{x} \in \mathbb{R}^d$, l'encoder produce una rappresentazione latente $\boldsymbol{z} \in \mathbb{R}^k$ con $k < d$, mentre il decoder genera una ricostruzione $\hat{\boldsymbol{x}}$:

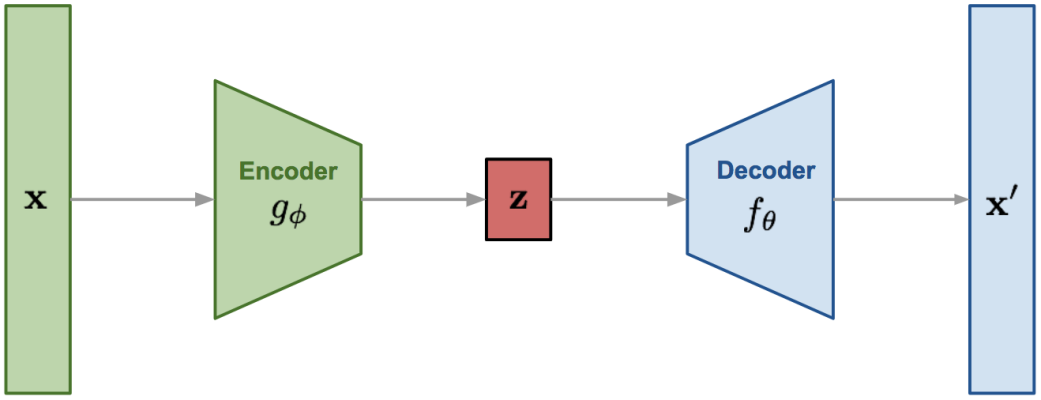


Figura 2.1: Schema generale di un autoencoder utilizzato per la anomaly detection basata sulla ricostruzione. L'encoder $\psi(\cdot)$ proietta l'input $\boldsymbol{x}$ in una rappresentazione latente $\boldsymbol{z}$, mentre il decoder $\phi(\cdot)$ produce una ricostruzione $\hat{\boldsymbol{x}}$ dello spazio di input.

$$\boldsymbol{z} = \psi(\boldsymbol{x}), \qquad \hat{\boldsymbol{x}} = \phi(\boldsymbol{z}) = \phi(\psi(\boldsymbol{x})). \tag{2.2}$$

L'addestramento dell'autoencoder avviene minimizzando una funzione di loss di ricostruzione, tipicamente l'errore quadratico medio:

$$\mathcal{L}_{\text{rec}}(\boldsymbol{x}) = \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|_2^2. \tag{2.3}$$

Nel contesto della anomaly detection, l'errore di ricostruzione viene utilizzato come score di anomalia:

$$s(\boldsymbol{x}) = \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|_2^2. \tag{2.4}$$

L'ipotesi sottostante è che l'autoencoder, essendo addestrato prevalentemente su dati nominali, impari a ricostruire correttamente i pattern frequenti della normalità, mentre fallisca nel ricostruire pattern rari o mai osservati, associati alle anomalie. Tuttavia, come verrà discusso nelle sezioni successive, tale ipotesi viene frequentemente violata in presenza di modelli ad alta capacità o dataset di training contaminati.

2.3 Autoencoder generativi

Gli autoencoder deterministici descritti nella sezione precedente apprendono una mappatura funzionale tra spazio di input e spazio latente, ma non forniscono una modellazione probabilistica esplicita dei dati. Per superare tale limitazione, sono stati proposti modelli generativi che interpretano l'autoencoder come un modello probabilistico latente, consentendo di associare a ciascun campione una misura di probabilità o di energia.

Nel contesto della anomaly detection, questa formulazione risulta particolarmente utile in quanto consente di definire score di anomalia più espressivi rispetto al solo errore di ricostruzione, e di integrare in modo naturale meccanismi di regolarizzazione e robustezza.

2.3.1 Variational Autoencoder

Il Variational Autoencoder (VAE) introduce una formulazione probabilistica del processo di codifica e decodifica. Si assume che i dati osservati $\boldsymbol{x}$ siano generati a partire da una variabile latente $\boldsymbol{z}$ secondo una distribuzione $p_\theta(\boldsymbol{x}|\boldsymbol{z})$, con un prior $p(\boldsymbol{z})$ tipicamente scelto come una distribuzione gaussiana standard.

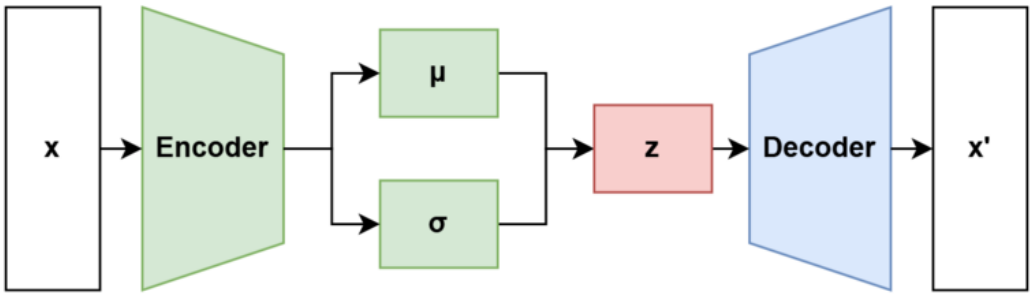


Figura 2.2: Schema di un Variational Autoencoder (VAE). L'encoder produce i parametri $\boldsymbol{\mu}$ e $\boldsymbol{\sigma}$ della distribuzione latente $q_\phi(\boldsymbol{z}|\boldsymbol{x})$, dalla quale viene campionato il vettore latente $\boldsymbol{z}$. Il decoder genera quindi una ricostruzione $\hat{\boldsymbol{x}}$ dell'input.

Poiché la distribuzione a posteriori $p(\boldsymbol{z}|\boldsymbol{x})$ è in generale intrattabile, il VAE introduce una distribuzione approssimata $q_\phi(\boldsymbol{z}|\boldsymbol{x})$ e ottimizza una stima inferiore della log-verosimiglianza marginale, nota come *Evidence Lower Bound* (ELBO):

$$\log p_\theta(\boldsymbol{x}) \geq \mathbb{E}_{q_\phi(\boldsymbol{z}|\boldsymbol{x})}[\log p_\theta(\boldsymbol{x}|\boldsymbol{z})] - D_{\mathrm{KL}}(q_\phi(\boldsymbol{z}|\boldsymbol{x})\|p(\boldsymbol{z})). \tag{2.5}$$

Il primo termine incoraggia una buona ricostruzione dei dati, mentre il secondo regolarizza la distribuzione latente, forzandola a rimanere vicina al prior.

Nel contesto della anomaly detection, la quantità

$$\mathcal{F}(\boldsymbol{x}) = -\mathbb{E}_{q_\phi(\boldsymbol{z}|\boldsymbol{x})}[\log p_\theta(\boldsymbol{x}|\boldsymbol{z})] + D_{\mathrm{KL}}(q_\phi(\boldsymbol{z}|\boldsymbol{x})\|p(\boldsymbol{z})) \tag{2.6}$$

viene spesso interpretata come *free energy* o *negative ELBO* ed è utilizzata come score di anomalia. Campioni nominali tendono a produrre valori bassi di $\mathcal{F}(\boldsymbol{x})$, mentre campioni anomali risultano associati a valori elevati.

2.3.2 Normalizing Flows

I Normalizing Flows (NF) estendono i modelli generativi latenti consentendo di modellare distribuzioni complesse tramite una sequenza di trasformazioni invertibili e differenziabili. Dato un vettore latente $\boldsymbol{z}_0$ campionato da una distribuzione semplice $p(\boldsymbol{z_0})$, una sequenza di trasformazioni

invertibili $\{f_k\}_{k=1}^{K}$ produce una variabile latente finale $\boldsymbol{z}_K$:

$$\boldsymbol{z}_K = f_K \circ f_{K-1} \circ \cdots \circ f_1(\boldsymbol{z}_0). \tag{2.7}$$

La densità di probabilità risultante può essere calcolata esattamente tramite la formula del cambiamento di variabile:

$$\log p(\boldsymbol{z}_K) = \log p(\boldsymbol{z}_0) - \sum_{k=1}^{K} \log \left| \det \frac{\partial f_k}{\partial \boldsymbol{z}_{k-1}} \right|. \tag{2.8}$$

Nel contesto dei VAE, i Normalizing Flows vengono spesso utilizzati per rendere più flessibile la distribuzione approssimata $q_\phi(z|x)$, migliorando la capacità del modello di adattarsi a distribuzioni latenti non gaussiane. In GRAnD, l'utilizzo dei Normalizing Flows consente di ottenere score di free energy più discriminativi, senza modificare la struttura generale del framework.

2.4 Extreme Value Theory per Anomaly Detection

La Extreme Value Theory (EVT) fornisce un quadro teorico per la modellazione degli eventi rari, concentrandosi sul comportamento delle code di una distribuzione. Nel contesto della anomaly detection, EVT risulta particolarmente adatta per modellare la distribuzione degli score di anomalia elevati, associati ai campioni più estremi.

A differenza di approcci parametrici globali, EVT consente di modellare esclusivamente la parte estrema della distribuzione, rendendo il metodo robusto alla forma complessiva degli score e alla presenza di contaminazione.

2.4.1 Peaks-Over-Threshold

L'approccio Peaks-Over-Threshold (POT) si basa sul teorema di Pickands–Balkema–de Haan, secondo il quale la distribuzione degli eccessi oltre una soglia sufficientemente elevata converge a una Generalized Pareto Distribution (GPD).

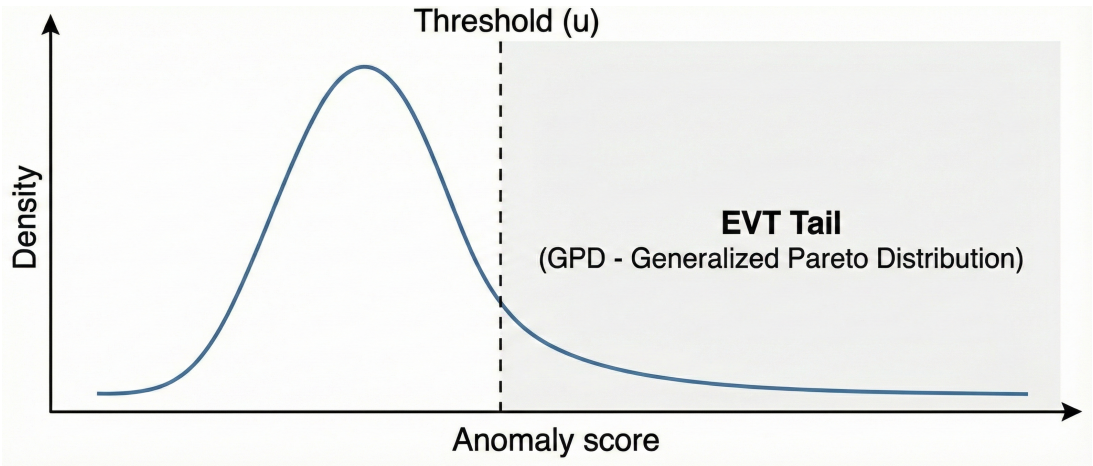


Figura 2.3: Illustrazione concettuale dell'approccio Peaks-Over-Threshold (POT). La distribuzione degli score di anomalia viene modellata tramite Extreme Value Theory oltre una soglia u, stimando la coda estrema mediante una Generalized Pareto Distribution (GPD).

Dato uno score di anomalia $s(\boldsymbol{x})$ e una soglia u, la distribuzione degli eccessi $y = s(\boldsymbol{x}) - u \mid s(\boldsymbol{x}) > u$ può essere modellata tramite una GPD:

$$G(y;\xi,\sigma) = \begin{cases} 1 - \left(1 + \frac{\xi y}{\sigma}\right)^{-1/\xi}, & \xi \neq 0 \\ 1 - \exp\left(-\frac{y}{\sigma}\right), & \xi = 0 \end{cases} \tag{2.9}$$

dove ξ è il parametro di forma e σ il parametro di scala.

Una volta stimati i parametri della GPD, è possibile determinare una soglia superiore t_q tale che la probabilità di osservare uno score maggiore di t_q sia inferiore a un livello di rischio prefissato q:

$$P(s(\boldsymbol{x}) > t_q) < q. \tag{2.10}$$

Questo meccanismo consente di definire soglie adattive e statisticamente fondate, che risultano particolarmente efficaci in scenari caratterizzati da distribuzioni fortemente sbilanciate e contaminate.

2.5 Robustezza e contaminazione nel training

In scenari reali di anomaly detection non supervisionata, il dataset di addestramento è spesso contaminato da una frazione ignota di campioni anomali. In presenza di modelli ad alta capacità, come gli autoencoder profondi, tale contaminazione può portare al fenomeno di *over-generalization*, per cui il modello riesce a ricostruire accuratamente anche campioni anomali.

Questo comportamento compromette l'efficacia degli approcci basati sulla ricostruzione, riducendo la separabilità tra dati nominali e anomali nello spazio degli score. Per questo motivo, sono state proposte diverse strategie per rendere il processo di apprendimento più robusto alla presenza di outlier.

2.5.1 Negative Learning come strategia alternativa

Una strategia alternativa al filtraggio esplicito degli outlier è rappresentata dal *negative learning*. In questo paradigma, i campioni ritenuti anomali non vengono ignorati, ma utilizzati attivamente per penalizzare una loro corretta ricostruzione.

Dato un insieme di campioni nominali $\mathcal{D}_L$ e un insieme di campioni anomali $\mathcal{D}_S$, una formulazione generale della funzione di loss può essere espressa come:

$$\mathcal{L} = \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}_L}[\mathcal{L}_{\text{rec}}(\boldsymbol{x})] + \lambda\, \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}_S}[\mathcal{L}_{\text{neg}}(\boldsymbol{x})], \tag{2.11}$$

dove $\mathcal{L}_{\text{neg}}$ è progettata per massimizzare l'errore di ricostruzione sui campioni anomali e λ controlla il bilanciamento tra i due termini.

Questo principio è alla base di framework come AESAD, nei quali il negative learning consente di sfruttare la presenza di pochi esempi anomali per rafforzare la separazione tra regioni nominali e anomale nello spazio latente. Tuttavia, l'efficacia di tali approcci dipende criticamente dalla qualità della stima iniziale dei campioni anomali, rendendo il metodo sensibile a errori di classificazione nelle prime fasi del training.

2.6 Stato dell'arte nella anomaly detection robusta

La anomaly detection non supervisionata è stata oggetto di un ampio numero di studi, che hanno proposto soluzioni basate su ipotesi e principi eterogenei. I primi approcci si fondano prevalentemente su metodi statistici o di *one-class classification*, come One-Class SVM e Isolation Forest, nei quali il comportamento nominale viene modellato implicitamente attraverso una frontiera decisionale o una misura di isolamento. Sebbene tali metodi risultino efficaci in scenari controllati, essi mostrano una sensibilità significativa alla presenza di contaminazione nel dataset di training, degradando rapidamente le prestazioni in assenza di dati puliti.

Con l'avvento del deep learning, numerosi lavori hanno esplorato l'utilizzo di autoencoder per la anomaly detection, sfruttando l'errore di ricostruzione come score di anomalia. Modelli come i Deep Autoencoder e le loro estensioni probabilistiche hanno dimostrato una maggiore capacità di rappresentare strutture non lineari nei dati, ma condividono una limitazione fondamentale: in presenza di campioni anomali nel training set, il modello tende a ricostruire anche tali campioni, riducendo il contrasto tra inlier e outlier [6].

Per affrontare questo problema, sono stati proposti approcci esplicitamente progettati per migliorare la robustezza dell'apprendimento. Zhou e Paffenroth introducono i *Robust Deep Autoencoder*, nei quali una componente di rumore sparso viene separata dalla rappresentazione latente, consentendo di attenuare l'influenza degli outlier durante il training [5]. In modo analogo, Akrami et al. propongono i *Robust Variational Autoencoder*, che sostituiscono la divergenza di Kullback–Leibler con una misura di divergenza robusta, riducendo il peso dei campioni con bassa probabilità [1]. Tali metodi, tuttavia, introducono iperparametri critici e richiedono ipotesi esplicite sulla distribuzione delle anomalie o sulla loro frequenza.

Una linea di ricerca complementare è rappresentata dagli approcci basati su *negative learning*, nei quali i campioni considerati anomali vengono utilizzati per penalizzare attivamente una loro corretta ricostruzione. In questo contesto, il framework AESAD introduce una funzione di loss che incorpora un termine di apprendimento negativo, forzando il modello a separare le regioni nominali e anomale nello spazio latente [2]. Questo paradigma consente di sfruttare la presenza di anomalie nel training set, ma richiede una strategia affidabile per l'identificazione dei campioni negativi, rendendo il metodo sensibile agli errori di classificazione iniziale.

Infine, recenti lavori hanno evidenziato l'efficacia dell'Extreme Value Theory (EVT) come strumento per la modellazione delle code estreme degli score di anomalia. In particolare, l'approccio Peaks-Over-Threshold consente di definire soglie adattive basate su un rischio prefissato, senza assumere una forma parametrica globale per la distribuzione degli score [4]. Su questa base si colloca il framework GRAnD, che combina modelli generativi con EVT per realizzare una strategia di apprendimento robusta alla contaminazione, evitando assunzioni forti sulla distribuzione o sulla percentuale delle anomalie presenti nel dataset di addestramento [3].

Capitolo 3

Il framework GRAnD

3.1 Panoramica generale

GRAnD (*Generative Robust Anomaly Detection*) è un framework per la anomaly detection non supervisionata progettato per operare in presenza di contaminazione nel dataset di addestramento. L'ipotesi di base è che, anche quando il training set contiene una frazione ignota di anomalie, queste tendano a produrre valori estremi di uno score di anomalia già nelle prime fasi dell'addestramento.

A differenza di approcci robusti che introducono assunzioni esplicite sulla distribuzione o sulla percentuale delle anomalie, GRAnD adotta una strategia iterativa che alterna due fasi principali:

- filtraggio dinamico dei campioni anomali presenti nel training set;
- apprendimento di una rappresentazione generativa robusta del comportamento nominale.

Il framework è concepito come un'estensione leggera di modelli generativi basati su autoencoder, in particolare Variational Autoencoder (VAE) e Normalizing Flows, e introduce una procedura di addestramento robusta senza modificare sostanzialmente l'architettura del modello.

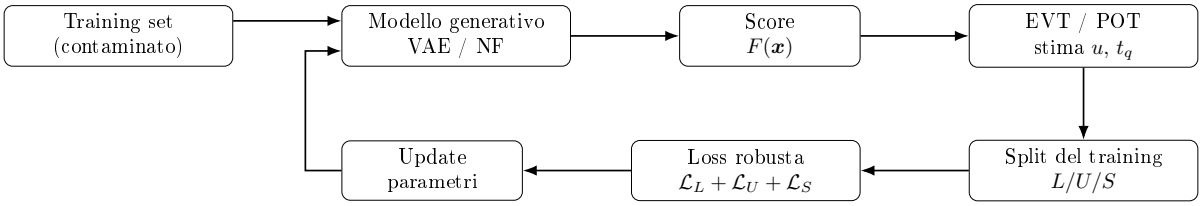


Figura 3.1: Schema generale del framework GRAnD. A ogni iterazione, il modello generativo produce uno score di free energy $\mathcal{F}(\boldsymbol{x})$; la coda degli score viene analizzata tramite EVT per stimare le soglie u e t_q, che inducono la suddivisione del training set in $L/U/S$ e la loss robusta.

3.2 Modello generativo e score di anomalia

GRAnD si basa su un modello generativo che apprende una distribuzione del comportamento nominale dei dati. Dato un campione $\boldsymbol{x} \in \mathbb{R}^d$ e una variabile latente $\boldsymbol{z}$, il modello massimizza una stima variazionale della log-verosimiglianza, espressa tramite la *negative free energy*:

$$F(\boldsymbol{x}) = -\mathbb{E}_{q_\phi(\boldsymbol{z}|\boldsymbol{x})}[\log p_\theta(\boldsymbol{x}|\boldsymbol{z})] + D_{\mathrm{KL}}(q_\phi(\boldsymbol{z}|\boldsymbol{x})\|p(\boldsymbol{z})). \tag{3.1}$$

Nel contesto della anomaly detection, il valore di $F(x)$ viene interpretato come uno score di anomalia: campioni nominali sono associati a valori bassi di free energy, mentre campioni anomali tendono a produrre valori elevati.

Per aumentare la flessibilità del modello generativo, GRAnD può essere implementato utilizzando Normalizing Flows nella distribuzione approssimata $q_\phi(z|x)$, consentendo di modellare distribuzioni latenti complesse e non gaussiane.

3.3 Strategia di rejection robusta basata su EVT

Il contributo centrale di GRAnD consiste in una strategia di filtraggio degli outlier basata su Extreme Value Theory (EVT). L'idea è modellare esplicitamente la coda estrema della distribuzione degli score di anomalia osservati nel training set, al fine di identificare campioni anomali senza fare assunzioni parametriche globali.

3.3.1 Definizione delle soglie u e t_q

Sia $\{F(x_i)\}_{i=1}^N$ l'insieme degli score di free energy associati ai campioni di training. GRAnD utilizza l'approccio Peaks-Over-Threshold (POT) per modellare gli score estremi che eccedono una soglia iniziale u.

In pratica, la soglia u viene definita in modo robusto utilizzando statistiche di ordine:

$$u = Q_3(F) + \alpha \cdot \mathrm{IQR}(F), \tag{3.2}$$

dove Q_3 è il terzo quartile, IQR è l'intervallo interquartile e α è un iperparametro che controlla la severità della soglia.

Gli score che eccedono u vengono modellati tramite una Generalized Pareto Distribution (GPD), stimata mediante massima verosimiglianza. Dato un livello di rischio q, viene quindi calcolata una soglia superiore t_q tale che:

$$P(F > t_q) < q. \tag{3.3}$$

3.3.2 Suddivisione dei dati in L, U e S

Sulla base delle soglie u e t_q, il training set viene suddiviso in tre sottoinsiemi disgiunti:

- L: campioni nominali, con $F(x) \leq u$;
- S: campioni fortemente anomali, con $F(x) \geq t_q$;
- U: campioni incerti, con $u < F(x) < t_q$.

Questa suddivisione consente di trattare in modo differenziato i campioni del training set, riflettendo diversi gradi di confidenza nella loro natura nominale o anomala.

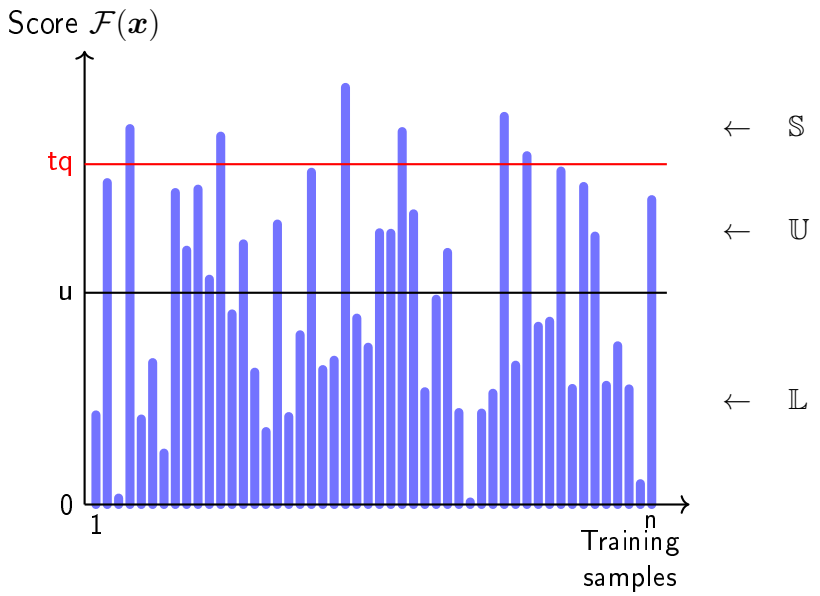


Figura 3.2: Esempio concettuale di suddivisione del training set nei sottoinsiemi nominali (L), incerti (U) e anomali (S) sulla base delle soglie EVT u e t_q applicate agli score di free energy $\mathcal{F}(\boldsymbol{x})$.

3.4 Funzione di loss di GRAnD

La funzione obiettivo di GRAnD è progettata per sfruttare attivamente la suddivisione $L/U/S$ del training set. L'addestramento mira a ottimizzare simultaneamente tre obiettivi distinti.

3.4.1 Loss sui campioni nominali

Per i campioni appartenenti a L, l'obiettivo è minimizzare la free energy:

$$\mathcal{L}_L = \mathbb{E}_{x\sim\mathcal{D}_L}[F(x)]. \tag{3.4}$$

Questo termine incoraggia una ricostruzione accurata dei campioni nominali.

3.4.2 Loss sui campioni anomali

Per i campioni fortemente anomali in S, GRAnD introduce un termine di loss che massimizza la free energy fino a un margine m:

$$\mathcal{L}_S = \left|m - \mathbb{E}_{x\sim\mathcal{D}_S}[F(x)]\right|. \tag{3.5}$$

Questo meccanismo forza il modello a ricostruire intenzionalmente in modo scorretto i campioni anomali, evitando che vengano assimilati al comportamento nominale.

3.4.3 Gestione dei campioni incerti

Per i campioni in U, GRAnD utilizza una strategia di pesatura basata sulla funzione di distribuzione cumulativa empirica (eCDF) degli score:

$$w(x) = \text{eCDF}(F(x)). \tag{3.6}$$

Il contributo di ciascun campione incerto alla loss è quindi modulato in base alla probabilità stimata di essere anomalo:

$$\mathcal{L}_U = w(x) \cdot |m - \mathbb{E}_{x \sim \mathcal{D}_U}[F(x)]| \,. \tag{3.7}$$

3.5 Obiettivo complessivo e algoritmo di training

La funzione obiettivo complessiva di GRAnD è data dalla combinazione dei tre termini:

$$\mathcal{L} = \mathcal{L}_L + \mathcal{L}_S + \mathcal{L}_U. \tag{3.8}$$

L'algoritmo di training alterna iterativamente:

1. il calcolo degli score di free energy;
2. la stima delle soglie EVT e la suddivisione $L/U/S$;
3. l'ottimizzazione della funzione di loss.

Questa procedura consente a GRAnD di adattarsi dinamicamente alla presenza di outlier nel training set, migliorando la robustezza del modello senza richiedere una stima preventiva della contaminazione.

Capitolo 4

Dataset e setup sperimentale

4.1 Dataset NSL-KDD

Per la valutazione sperimentale del framework GRAnD è stato utilizzato il dataset NSL-KDD, una versione migliorata del noto KDD Cup 1999, progettata per mitigare le problematiche di ridondanza e bias presenti nella versione originale. Il dataset NSL-KDD è ampiamente utilizzato come benchmark nella letteratura sulla network intrusion detection e consente una valutazione controllata delle prestazioni dei modelli di anomaly detection.

Il dataset è costituito da connessioni di rete descritte tramite 41 feature, comprendenti attributi continui, discreti e categoriali. Ogni campione rappresenta una singola connessione di rete e può essere associato a comportamento nominale oppure a una specifica tipologia di attacco. Nel presente lavoro, coerentemente con il paradigma di anomaly detection non supervisionata, le etichette sono utilizzate esclusivamente a fini di valutazione e non durante la fase di addestramento.

4.1.1 Preprocessing e feature engineering

Prima dell'addestramento del modello, il dataset NSL-KDD è stato sottoposto a una fase di preprocessing volta a rendere i dati compatibili con modelli basati su autoencoder. Le feature categoriali sono state trasformate mediante codifica one-hot, mentre le feature numeriche sono state normalizzate tramite standardizzazione a media zero e varianza unitaria.

Questa trasformazione comporta un aumento della dimensionalità dello spazio di input e introduce una forte sparsità nei dati, in particolare per le feature categoriali. Tali caratteristiche rendono il dataset particolarmente sfidante per i modelli basati sulla ricostruzione, in quanto favoriscono fenomeni di over-generalization e amplificano l'effetto della contaminazione nel training set.

4.1.2 Strategia di contaminazione

Per analizzare il comportamento del framework GRAnD in presenza di dati contaminati, il training set è stato costruito introducendo una frazione controllata di campioni anomali. In particolare, sono stati considerati quattro livelli di contaminazione, pari allo 0%, 5%, 10% e 15% del numero totale di campioni nel training set.

Per ciascun livello di contaminazione, i campioni anomali sono stati selezionati casualmente dal dataset etichettato e inseriti nel training set nominale, mantenendo invariata la distribuzione del test set. Questa procedura consente di valutare in modo sistematico la robustezza del modello al crescere della contaminazione e di analizzarne il comportamento in scenari progressivamente più sfidanti.

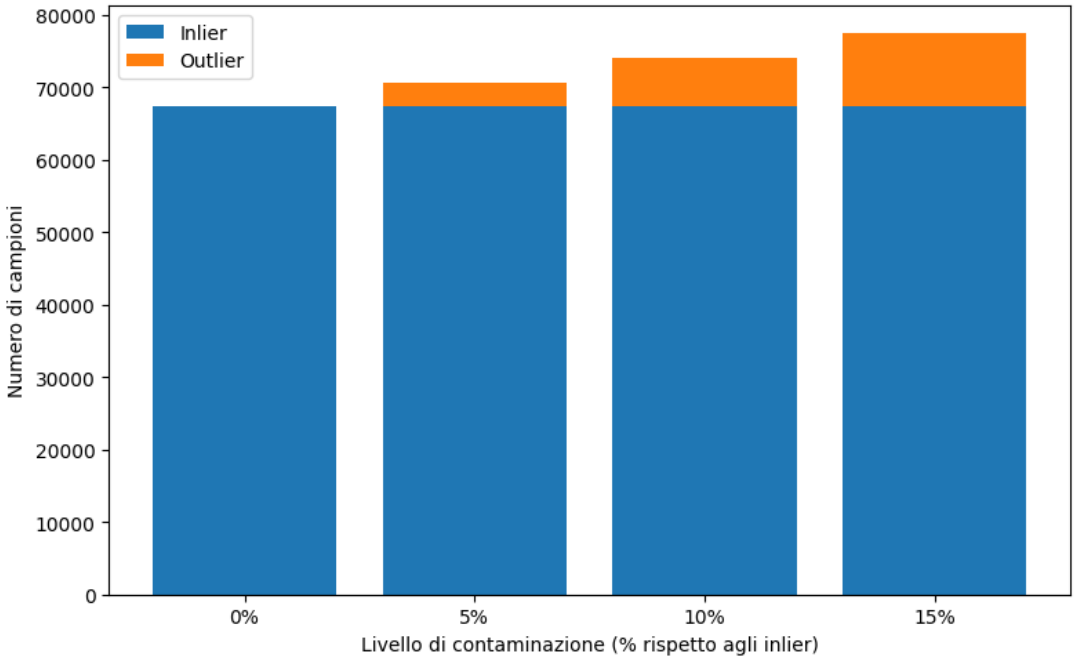


Figura 4.1: Distribuzione dei campioni nominali (inlier) e anomali (outlier) nel training set per i diversi livelli di contaminazione considerati. Il numero di campioni nominali è mantenuto fisso, mentre i campioni anomali sono aggiunti in percentuale rispetto agli inlier (0%, 5%, 10%, 15%).

4.2 Protocollo sperimentale

L'addestramento e la valutazione dei modelli sono stati condotti seguendo un protocollo sperimentale coerente con il paper originale di GRAnD, al fine di garantire una replicazione fedele dei risultati. Il dataset è stato suddiviso in un insieme di training e un insieme di test, utilizzando esclusivamente il training set per l'ottimizzazione del modello.

Le metriche di valutazione considerate includono l'Area Under the Receiver Operating Characteristic Curve (AUROC) e l'Area Under the Precision-Recall Curve (AUPRC), particolarmente rilevante in presenza di dataset fortemente sbilanciati.

4.3 Dettagli computazionali

Tutti gli esperimenti sono stati eseguiti su una macchina desktop con le seguenti specifiche hardware:

- CPU: Intel Core i7-3770 @ 3.40 GHz;
- RAM: 16 GB DDR3;

- GPU: NVIDIA GeForce GTX 770 (2 GB).

Nonostante la presenza di una GPU dedicata, tutti gli esperimenti sono stati eseguiti utilizzando esclusivamente la CPU. Questa scelta è motivata dalla volontà di garantire la riproducibilità degli esperimenti su hardware comunemente disponibile e di valutare il costo computazionale del framework GRAnD in scenari a risorse limitate.

Il training su CPU comporta tempi di addestramento più elevati rispetto a implementazioni GPU-based, ma non influisce sulla correttezza dei risultati ottenuti. Inoltre, la struttura modulare del framework consente un'agevole estensione a scenari di addestramento accelerato tramite GPU, qualora necessario.

4.4 Considerazioni preliminari

Le caratteristiche del dataset NSL-KDD, in particolare l'elevata dimensionalità dopo il preprocessing, la presenza di feature sparse e la contaminazione controllata del training set, rendono questo benchmark particolarmente adatto alla valutazione di approcci robusti basati sulla ricostruzione.

In questo contesto, l'uso di soglie adattive basate su Extreme Value Theory e di strategie di apprendimento robuste, come quelle introdotte in GRAnD, risulta motivato sia dal punto di vista teorico che pratico. Le sezioni successive analizzeranno in dettaglio il comportamento del modello durante il training e le prestazioni ottenute nei diversi scenari sperimentali considerati.

Le configurazioni sperimentali e il protocollo descritti in questo capitolo verranno utilizzati come riferimento per la valutazione del framework GRAnD e delle estensioni proposte nei capitoli successivi.

Capitolo 5

Proposte di miglioramento del framework GRAnD

In questo capitolo vengono presentate una serie di estensioni e modifiche al framework GRAnD con l'obiettivo di migliorarne la stabilità numerica, la robustezza al rumore nel training set contaminato e la controllabilità del processo di apprendimento. Le proposte discusse non alterano l'impianto concettuale originale di GRAnD, ma ne rafforzano la coerenza teorica e la praticabilità sperimentale, soprattutto in scenari reali caratterizzati da dati rumorosi e distribuzioni non stazionarie.

Un aspetto chiave del lavoro svolto è stato il refactoring completo del codice, rendendo ogni componente del framework modulare e configurabile tramite parametri di training. Questo ha permesso di testare in modo sistematico ciascuna proposta mediante semplici variazioni di configurazione, senza introdurre dipendenze strutturali tra le diverse estensioni.

5.1 Stabilizzazione del training dinamico

Il framework GRAnD è caratterizzato da una dinamica di training intrinsecamente accoppiata, in cui l'ottimizzazione dei parametri del modello, la stima delle soglie EVT e la partizione del dataset nei sottoinsiemi L, U e S evolvono simultaneamente. A differenza di un autoencoder standard, la funzione obiettivo ottimizzata a ogni epoca dipende direttamente dalle soglie stimate sull'energia e, di conseguenza, dalla distribuzione delle rappresentazioni apprese dal modello stesso.

Questa interdipendenza introduce una potenziale instabilità numerica, particolarmente marcata nelle fasi iniziali del training, quando la distribuzione delle energie non è ancora strutturata e le stime EVT risultano fortemente rumorose. Le tecniche discusse in questa sezione mirano a stabilizzare tale dinamica, introducendo meccanismi di controllo progressivo e regolarizzazione temporale, senza alterare l'impianto concettuale originale di GRAnD.

5.1.1 Warmup e ramp sulle componenti della funzione obiettivo

Nel framework GRAnD originale, la funzione di perdita è definita come:

$$\mathcal{L}_{\text{GRAnD}} = \mathbb{E}_{x\sim L}[E(x)] + \mathbb{E}_{x\sim U}[w(x)\,|m - E(x)|] + \mathbb{E}_{x\sim S}[|m - E(x)|],$$

dove $E(x)$ rappresenta la free-energy associata al campione x, e $w(x)$ è un peso derivato dalla distribuzione empirica delle energie nell'insieme U.

Nelle prime epoche di training, tuttavia, la rappresentazione latente appresa dal modello è ancora instabile e la partizione nei sottoinsiemi L, U e S risulta fortemente dipendente da soglie stimate su una distribuzione delle energie non ancora affidabile. In questa fase, l'uso diretto dei termini di penalizzazione sugli insiemi U e S può introdurre gradienti rumorosi e compromettere l'apprendimento della distribuzione nominale.

Per mitigare questo effetto, vengono introdotti coefficienti temporali $\lambda_U(e)$ e $\lambda_S(e)$ che modulano progressivamente l'influenza dei termini associati agli insiemi U e S:

$$\mathcal{L}(e) = \mathbb{E}_{x\sim L}[E(x)] + \lambda_U(e)\,\mathbb{E}_{x\sim U}[w(x)\,|m - E(x)|] + \lambda_S(e)\,\mathbb{E}_{x\sim S}[|m - E(x)|].$$

I coefficienti $\lambda(e)$ seguono una strategia di warmup seguita da una rampa lineare:

$$\lambda(e) = \begin{cases} 0 & e \le e_{\text{warm}}, \\ \frac{e - e_{\text{warm}}}{e_{\text{ramp}}} & e_{\text{warm}} < e < e_{\text{warm}} + e_{\text{ramp}}, \\ 1 & e \ge e_{\text{warm}} + e_{\text{ramp}}. \end{cases}$$

Durante la fase di warmup iniziale, il modello si comporta quindi come un autoencoder standard, focalizzandosi esclusivamente sulla buona ricostruzione dei campioni nominali. Solo in una fase successiva vengono introdotti gradualmente i termini di separazione esplicita degli outlier, quando la rappresentazione latente risulta più stabile. Questa separazione temporale riduce la sensibilità iniziale del meccanismo di thresholding EVT e contribuisce a una maggiore stabilità complessiva del training.

5.1.2 Loss a margine con funzione liscia

Nel framework GRAnD, la penalizzazione dei campioni appartenenti agli insiemi U e S è basata su una loss a margine del tipo:

$$\ell(E) = |m - E|,$$

dove m rappresenta il margine e E la free-energy del campione.

Questa formulazione introduce una discontinuità nella derivata prima in corrispondenza di $E = m$, che può causare instabilità durante l'ottimizzazione, in particolare in presenza di:

- soglie dinamiche u e t_q;
- variazioni rapide nella partizione $L/U/S$;
- pesi $w(x)$ dipendenti dalla distribuzione empirica delle energie.

Per migliorare la stabilità differenziale del processo di training, è stata introdotta una versione liscia della loss a margine basata sulla funzione Softplus:

$$\text{softabs}_\tau(x) = \tau \log(1 + e^{x/\tau}) + \tau \log(1 + e^{-x/\tau}),$$

che approssima il valore assoluto e soddisfa:

$$\lim_{\tau \to 0} \text{softabs}_\tau(x) = |x|.$$

La nuova penalizzazione è quindi definita come:

$$\ell_{\text{smooth}}(E) = \text{softabs}_\tau(m - E),$$

garantendo continuità e derivabilità ovunque.

Questa sostituzione non altera l'interpretazione geometrica della loss a margine, ma riduce oscillazioni del gradiente in prossimità del margine m, contribuendo alla stabilità complessiva del training dinamico di GRAnD.

5.1.3 Strategie di thresholding EVT

Il meccanismo di thresholding basato su Extreme Value Theory rappresenta uno degli elementi centrali del framework GRAnD, poiché determina la partizione del dataset nei sottoinsiemi L, U e S sulla base della distribuzione delle energie. Tuttavia, la stima delle soglie EVT è particolarmente sensibile a diversi fattori, tra cui:

- la numerosità limitata delle exceedances oltre la soglia u;
- l'instabilità della stima del parametro di forma ξ della GPD;
- la non stazionarietà della distribuzione delle energie nelle prime epoche.

Nel framework originale di GRAnD, la soglia u viene definita come:

$$u = Q_3(E) + \alpha \cdot \text{IQR}(E),$$

mentre la soglia superiore t_q viene stimata mediante il metodo Peaks-Over-Threshold, assumendo che le exceedances seguano una Generalized Pareto Distribution.

Per migliorare la stabilità numerica del processo, sono state investigate diverse strategie di thresholding alternative:

1. **POT classico**, basato sulla stima dei parametri (ξ, σ) della GPD;
2. **POT con cap empirico**, in cui la soglia t_q è limitata superiormente dal quantile empirico Q_{1-q}:
$$t_q = \min(t_q^{\text{POT}}, Q_{1-q});$$
3. **POT con stima SciPy**, che utilizza una stima robusta dei parametri GPD e gestisce casi di degenerazione del fitting;
4. **POT con smoothing temporale**, in cui le soglie vengono regolarizzate tramite una Exponential Moving Average:
$$t_q^{(e)} = \beta\, t_q^{(e-1)} + (1 - \beta)\, \hat{t}_q^{(e)};$$

5. **Double quantile thresholding**, completamente non parametrico, definito come:

$$u = Q_{1-q_{\text{low}}}, \quad t_q = Q_{1-q}.$$

La stabilità delle soglie u e t_q è cruciale, poiché esse influenzano direttamente sia la partizione $L/U/S$ sia la funzione obiettivo ottimizzata a ogni epoca. Tutte le strategie sono state progettate in modo intercambiabile, consentendo di analizzare sistematicamente il trade-off tra rigore statistico e stabilità numerica.

5.1.4 Curriculum learning sulle soglie EVT

Un'ulteriore fonte di instabilità nel training di GRAnD deriva dall'utilizzo diretto della soglia EVT t_q fin dalle prime epoche. In questa fase, la distribuzione delle energie non è ancora sufficientemente strutturata e la stima EVT può risultare fortemente rumorosa, portando a una classificazione prematura di campioni come fortemente anomali.

Per mitigare questo effetto, è stato introdotto un curriculum learning sulla soglia superiore, che interpola progressivamente tra una soglia empirica basata sul quantile e la soglia stimata tramite EVT:

$$t_q^{(e)} = (1 - \beta(e))\, t_q^{\text{emp}} + \beta(e)\, t_q^{\text{POT}},$$

dove $t_q^{\text{emp}} = Q_{1-q}$ e $\beta(e)$ segue una rampa temporale analoga a quella utilizzata per il warmup della loss.

Durante le prime epoche, il processo di filtraggio si basa quindi su una soglia puramente empirica, più stabile ma meno selettiva. Solo successivamente viene introdotta progressivamente la soglia EVT, quando la distribuzione delle energie risulta sufficientemente affidabile.

Questo approccio introduce una forma di curriculum learning non sullo spazio delle rappresentazioni latenti, ma sulla politica di decisione che separa le regioni nominali e anomale dello spazio delle osservazioni.

5.1.5 Discussione sulla stabilità complessiva

Le tecniche descritte in questa sezione — warmup e ramp della loss, strategie avanzate di thresholding e curriculum learning sulle soglie — agiscono in modo complementare per stabilizzare la dinamica di training di GRAnD. In particolare, esse consentono di:

- separare temporalmente l'apprendimento della rappresentazione nominale dalla fase di separazione degli outlier;
- ridurre l'impatto di stime EVT rumorose nelle prime epoche;
- limitare oscillazioni improvvise nella cardinalità degli insiemi L, U e S;
- attenuare discontinuità e instabilità del gradiente in prossimità del margine energetico.

Nel complesso, queste strategie trasformano il training di GRAnD da un processo fortemente reattivo a una dinamica controllata e progressiva, migliorandone la robustezza e la riproducibilità. In particolare, la combinazione di regolarizzazione temporale, stabilizzazione delle soglie

e lisciamento della funzione di perdita consente di governare simultaneamente le componenti temporali, decisionali e differenziali del processo di ottimizzazione.

5.2 Integrazione del negative learning nel framework GRAnD

Come discusso nel Capitolo 2, il negative learning fornisce un meccanismo per ridurre esplicitamente la capacità ricostruttiva di un autoencoder su campioni anomali, contrastando la tendenza alla generalizzazione eccessiva tipica dei modelli generativi. In questa sezione viene descritto come tale principio venga integrato operativamente nel framework GRAnD, mantenendo invariato il suo impianto concettuale e sfruttando la partizione dinamica del dataset in insiemi a diverso livello di confidenza.

L'obiettivo dell'integrazione non è quello di sostituire la penalizzazione energetica di GRAnD, bensì di affiancarla con un termine che agisce direttamente nello spazio delle osservazioni, rafforzando la separazione strutturale tra campioni nominali e anomali.

5.2.1 Motivazione dell'integrazione

Nel framework GRAnD, il meccanismo di thresholding basato su EVT consente di identificare dinamicamente un insieme S di campioni che, con elevata probabilità, appartengono alla coda estrema della distribuzione delle energie. Tuttavia, la penalizzazione introdotta da GRAnD sugli insiemi U e S agisce esclusivamente sullo score energetico, senza intervenire direttamente sulla capacità ricostruttiva del decoder.

L'integrazione del negative learning mira a colmare questa lacuna, introducendo una penalizzazione esplicita sulla ricostruzione dei campioni identificati come fortemente sospetti. In questo senso, l'insieme S può essere interpretato come una stima operativa dell'insieme di anomalie utilizzato nei framework di negative learning, rendendo naturale l'estensione di GRAnD in questa direzione.

L'approccio adottato consente di rafforzare la separazione tra regioni nominali e anomale dello spazio delle osservazioni, senza richiedere assunzioni aggiuntive sulla distribuzione degli outlier.

5.2.2 Applicazione selettiva sugli insiemi S e U

A differenza dei framework di negative learning classici, in GRAnD l'insieme dei campioni non nominali non è noto a priori ed è caratterizzato da un diverso livello di incertezza. In particolare, l'insieme U contiene campioni critici che non possono essere classificati con elevata confidenza come nominali o anomali.

Applicare indiscriminatamente il negative learning a tutti i campioni in U potrebbe introdurre un bias sistematico, compromettendo la qualità della rappresentazione nominale appresa dal modello. Per questo motivo, il termine di negative learning viene applicato in modo selettivo:

- a tutti i campioni appartenenti all'insieme S;
- a un sottoinsieme di campioni in U caratterizzati da energia elevata, selezionati dinamicamente durante il training.

Questa strategia consente di sfruttare il principio del negative learning preservando al contempo la natura conservativa del meccanismo di filtraggio di GRAnD.

5.2.3 Funzioni distruttive dell'input

Il negative learning viene implementato tramite l'introduzione di trasformazioni distruttive $F(\cdot)$ applicate all'input. Tali trasformazioni hanno lo scopo di allontanare il campione dalla manifold nominale, senza introdurre strutture artificiali che potrebbero essere sfruttate dal modello.

Sono state considerate diverse funzioni $F(\cdot)$:

- **Inversione totale**, definita come $F(x) = 1 - x$ per feature normalizzate;
- **Inversione parziale**, applicata a un sottoinsieme casuale delle feature;
- **Feature swapping**, in cui un sottoinsieme di feature viene scambiato tra campioni distinti.

In particolare, il feature swapping risulta particolarmente adatto a dataset eterogenei e ad alta dimensionalità, come NSL-KDD, poiché preserva la distribuzione marginale delle singole feature rompendo al contempo le dipendenze congiunte.

5.2.4 Scheduling del negative learning e interazione con la loss GRAnD

Per evitare interferenze nelle fasi iniziali del training, il termine di negative learning viene introdotto progressivamente mediante un coefficiente temporale $\lambda_A(e)$, soggetto a warmup e rampa lineare. Durante le prime epoche, il contributo del negative learning è nullo, consentendo al modello di apprendere una rappresentazione stabile della distribuzione nominale.

La funzione obiettivo complessiva del framework GRAnD esteso assume quindi la forma:

$$\mathcal{L} = \mathcal{L}_{\text{GRAnD}} + \lambda_A(e)\mathbb{E}_{x \sim S \cup U_{\text{high}}} \left[\|\hat{x} - F(x)\|^2 \right],$$

dove $U_{\text{high}} \subseteq U$ indica il sottoinsieme di campioni in U selezionati in base al loro livello energetico.

Questa formulazione preserva l'impianto originale di GRAnD, rafforzando la separazione strutturale tra campioni nominali e anomali e migliorando la robustezza del modello in presenza di contaminazione nel training set.

5.2.5 Considerazioni finali

L'integrazione del negative learning nel framework GRAnD sfrutta in modo diretto la partizione dinamica del dataset per applicare una penalizzazione mirata sui campioni più sospetti. Questo approccio consente di combinare i benefici della penalizzazione energetica con quelli della penalizzazione nello spazio delle osservazioni, mantenendo un controllo esplicito sul livello di aggressività del negative learning.

Nel capitolo successivo verrà valutato sperimentalmente l'impatto di questo termine aggiuntivo, sia in termini di separazione delle energie sia in termini di metriche aggregate di anomaly detection.

5.3 Early stopping basato su convergenza strutturale

Nel framework GRAnD, il processo di training non si limita all'ottimizzazione dei parametri del modello generativo, ma coinvolge l'evoluzione simultanea di più componenti interdipendenti: la funzione obiettivo, le soglie di thresholding EVT e la partizione del dataset nei sottoinsiemi L, U e S. Di conseguenza, criteri di early stopping basati esclusivamente sulla stabilizzazione della loss risultano inadeguati a catturare la reale convergenza del sistema.

Per affrontare questa problematica, è stato introdotto un criterio di early stopping basato sul concetto di *convergenza strutturale*, che valuta la stabilità congiunta delle principali grandezze che governano la dinamica di GRAnD.

5.3.1 Grandezze monitorate

Sia e l'indice di epoca. Durante il training vengono monitorate le seguenti quantità:

- la loss media $\mathcal{L}^{(e)}$;
- la soglia inferiore EVT $u^{(e)}$;
- la soglia superiore EVT $t_q^{(e)}$;
- le cardinalità normalizzate dei sottoinsiemi:

$$p_L^{(e)} = \frac{|L^{(e)}|}{n}, \quad p_U^{(e)} = \frac{|U^{(e)}|}{n}, \quad p_S^{(e)} = \frac{|S^{(e)}|}{n}.$$

Queste grandezze forniscono una descrizione compatta ma informativa dello stato del sistema, catturando sia l'andamento dell'ottimizzazione sia la stabilità del meccanismo di filtraggio basato su EVT.

5.3.2 Misure di stabilità su finestra temporale

Per valutare la convergenza, viene considerata una finestra temporale scorrevole di ampiezza W, contenente gli ultimi W valori osservati di ciascuna grandezza monitorata. Per una sequenza generica $\{z^{(e)}\}_{e=e_0}^{e_0+W-1}$ viene definita una misura di stabilità relativa come:

$$\Delta_{\text{rel}}(z) = \frac{\max_e z^{(e)} - \min_e z^{(e)}}{|\mathbb{E}[z^{(e)}]| + \varepsilon},$$

dove ε è un termine di regolarizzazione per evitare divisioni per zero.

Per le frazioni normalizzate p_L, p_U e p_S, viene invece utilizzata una misura di stabilità assoluta:

$$\Delta_{\text{abs}}(p) = \max_e p^{(e)} - \min_e p^{(e)}.$$

Questa distinzione riflette la diversa scala e interpretazione delle grandezze monitorate.

5.3.3 Criterio di arresto

Il training viene interrotto quando, al termine della fase di warmup iniziale, tutte le seguenti condizioni risultano simultaneamente soddisfatte:

$$\Delta_{\text{rel}}(\mathcal{L}) < \epsilon_{\mathcal{L}}, \quad \Delta_{\text{rel}}(u) < \epsilon_u, \quad \Delta_{\text{rel}}(t_q) < \epsilon_{t_q}, \quad \max\big(\Delta_{\text{abs}}(p_L), \Delta_{\text{abs}}(p_U), \Delta_{\text{abs}}(p_S)\big) < \epsilon_p.$$

Le soglie $\epsilon_{\mathcal{L}}$, ϵ_u, ϵ_{t_q} ed ϵ_p consentono di controllare la sensibilità del criterio di arresto e possono essere regolate in funzione del dataset e del livello di rumore atteso.

5.3.4 Interpretazione come convergenza strutturale

Il criterio proposto può essere interpretato come una nozione di convergenza strutturale del framework GRAnD. L'arresto del training non avviene quando una singola quantità si stabilizza, ma quando:

- l'ottimizzazione del modello non produce più variazioni significative della loss;
- le soglie EVT risultano stabili nel tempo;
- la partizione del dataset nei sottoinsiemi L, U e S non subisce oscillazioni rilevanti.

In questo regime, il modello e il meccanismo di filtraggio hanno raggiunto un equilibrio dinamico, rendendo improbabili ulteriori miglioramenti significativi attraverso l'estensione del training.

5.3.5 Vantaggi del criterio proposto

L'early stopping basato su convergenza strutturale presenta diversi vantaggi rispetto a criteri tradizionali:

- evita arresti prematuri dovuti a fluttuazioni temporanee della loss;
- previene overfitting tardivo causato da oscillazioni numeriche delle soglie EVT;
- riduce il costo computazionale, interrompendo il training quando il sistema è stabilizzato;
- fornisce un criterio di arresto interpretabile e coerente con la natura dinamica di GRAnD.

Questo approccio risulta particolarmente adatto a contesti di anomaly detection non supervisionata, in cui non è disponibile un validation set etichettato su cui basare criteri di arresto standard.

5.4 Explainability by design

Uno dei principali limiti dei modelli di anomaly detection basati su autoencoder è la scarsa interpretabilità dello score di anomalia, che spesso risulta essere una quantità aggregata priva di una spiegazione diretta in termini di attributi osservabili. Nel framework GRAnD, invece,

la definizione dello score di anomalia come *free-energy* consente una forma di explainability intrinseca, derivante direttamente dalla struttura del modello e della funzione obiettivo.

In questa sezione viene mostrato come GRAnD consenta un'analisi esplicativa *by design*, senza ricorrere a modelli surrogati o tecniche post-hoc esterne.

5.4.1 Decomposizione strutturale dello score di anomalia

Nel framework GRAnD, lo score di anomalia associato a un campione $x \in \mathbb{R}^d$ è definito come:

$$E(x) = \sum_{j=1}^{d} (x_j - \hat{x}_j)^2 + \log_\text{term}(x),$$

dove $\hat{x}$ rappresenta la ricostruzione del campione e $\log_\text{term}(x)$ è il termine derivante dalla componente probabilistica del modello latente.

Questa formulazione consente una decomposizione naturale dello score totale in due contributi distinti:

- un termine di errore di ricostruzione, ulteriormente scomponibile per-feature;
- un termine globale che riflette la plausibilità latente del campione.

La presenza esplicita di questi due contributi permette di distinguere tra anomalie guidate principalmente da discrepanze locali nelle feature e anomalie dovute a incoerenze globali nello spazio latente.

5.4.2 Explainability basata sull'errore di ricostruzione

Il termine di errore di ricostruzione può essere analizzato a livello di singola feature come:

$$\text{MSE}_j(x) = (x_j - \hat{x}_j)^2.$$

Questo consente di costruire spiegazioni locali per ciascun campione, identificando le feature che contribuiscono maggiormente allo score di anomalia. Nel caso di feature categoriche codificate tramite one-hot encoding, l'errore di ricostruzione fornisce inoltre un'indicazione diretta di mismatch semantico tra input e output.

Per dataset eterogenei come NSL-KDD, è possibile aggregare i contributi per-feature in famiglie semantiche (ad esempio `protocol_type`, `service`, `flag`), ottenendo spiegazioni più compatte e interpretabili.

5.4.3 Explainability gradient-based sullo score energetico

Sebbene l'errore di ricostruzione fornisca una spiegazione immediata, in molti casi lo score di anomalia è dominato dal termine globale $\log_\text{term}(x)$. In tali situazioni, l'analisi basata esclusivamente sull'errore di ricostruzione risulta insufficiente.

Per questo motivo, viene introdotta una tecnica di explainability gradient-based basata su Integrated Gradients, applicata direttamente allo score energetico totale $E(x)$. Dato un baseline

x_0, l'attribuzione per-feature è definita come:

$$\mathrm{IG}_j(x) = (x_j - x_{0,j}) \int_0^1 \frac{\partial E(x_0 + \alpha(x - x_0))}{\partial x_j}\, d\alpha.$$

Questa formulazione consente di attribuire a ciascuna feature il contributo marginale allo score di anomalia, anche quando tale contributo non si manifesta direttamente come errore di ricostruzione.

5.4.4 Selezione adattiva della modalità esplicativa

La decomposizione dello score energetico consente di selezionare dinamicamente la modalità esplicativa più informativa. In particolare, definendo la frazione di energia attribuibile all'errore di ricostruzione come:

$$\rho(x) = \frac{\sum_{j=1}^{d} (x_j - \hat{x}_j)^2}{E(x)},$$

è possibile distinguere tra:

- anomalie guidate prevalentemente da errori di ricostruzione ($\rho(x)$ elevato);
- anomalie guidate prevalentemente dal termine latente ($\rho(x)$ ridotto).

Nel primo caso, l'analisi per-feature basata sull'errore di ricostruzione risulta più interpretabile. Nel secondo caso, l'uso di metodi gradient-based sullo score energetico fornisce una spiegazione più fedele.

5.4.5 Vantaggi dell'approccio by design

L'approccio di explainability adottato in GRAnD presenta diversi vantaggi:

- non richiede l'addestramento di modelli ausiliari o surrogate models;
- è direttamente allineato con la funzione obiettivo ottimizzata dal modello;
- fornisce spiegazioni locali coerenti con lo score di anomalia;
- si adatta naturalmente a dati ad alta dimensionalità e misti.

Nel complesso, l'explainability non rappresenta un'aggiunta esterna al framework, ma emerge come una proprietà intrinseca della definizione stessa dello score di anomalia in GRAnD. Nel capitolo successivo verranno presentati esempi concreti di spiegazioni locali, mostrando come le tecniche descritte consentano di interpretare in modo sistematico le decisioni del modello.

5.5 Estensione architetturale del framework: GRAnD-ResMLP

Il framework GRAnD, nella sua formulazione originale, utilizza un autoencoder fully-connected relativamente compatto, progettato per garantire stabilità e semplicità implementativa. Tuttavia, in scenari caratterizzati da input ad alta dimensionalità e forte eterogeneità delle feature, come

nel caso del dataset NSL-KDD, architetture più profonde e con maggiore capacità espressiva possono risultare vantaggiose.

Per questo motivo, è stata introdotta una variante architetturale di GRAnD basata su blocchi ResMLP, mantenendo invariata la funzione obiettivo, il meccanismo di thresholding EVT e la dinamica complessiva del training. L'obiettivo di questa estensione è valutare l'impatto di una maggiore capacità rappresentazionale sul processo di anomaly detection, senza alterare i principi fondanti del framework.

5.5.1 Motivazione architetturale

Le architetture MLP profonde soffrono spesso di problemi di degradazione del gradiente e instabilità durante l'ottimizzazione, in particolare quando accoppiate a meccanismi dinamici come quelli presenti in GRAnD. L'introduzione di connessioni residue consente di mitigare tali problematiche, favorendo una propagazione più stabile del gradiente e una maggiore robustezza dell'ottimizzazione.

In questo contesto, i blocchi ResMLP rappresentano una scelta naturale, poiché permettono di aumentare la profondità del modello mantenendo un comportamento vicino all'identità nelle prime fasi del training.

5.5.2 Architettura ResMLP per GRAnD

Nella variante GRAnD-ResMLP, l'encoder e il decoder sono costruiti come una sequenza di blocchi residuali. Ciascun blocco implementa una trasformazione del tipo:

$$h_{l+1} = h_l + f_{\theta_l}(h_l),$$

dove h_l rappresenta l'attivazione al livello l e $f_{\theta_l}(\cdot)$ è una funzione non lineare parametrizzata, tipicamente composta da:

- un layer fully-connected;
- una funzione di attivazione non lineare;
- eventuali meccanismi di normalizzazione.

La struttura residua consente di interpretare l'architettura come una perturbazione controllata dell'identità, facilitando l'ottimizzazione anche in presenza di molteplici layer.

5.5.3 Integrazione con il framework GRAnD

L'estensione architetturale proposta non modifica in alcun modo:

- la definizione dello score energetico;
- la funzione obiettivo di GRAnD;
- il meccanismo di thresholding basato su EVT;
- le strategie di stabilizzazione del training e negative learning.

Di conseguenza, tutte le tecniche discusse nelle sezioni precedenti risultano direttamente applicabili anche alla variante GRAnD-ResMLP. Questo aspetto sottolinea la natura architetturalmente agnostica del framework GRAnD, che può essere combinato con modelli generativi di diversa complessità.

5.5.4 Considerazioni su capacità e costo computazionale

L'adozione di un'architettura ResMLP comporta un aumento del numero di parametri e del costo computazionale per epoca. Tuttavia, tale incremento è compensato da una maggiore capacità di modellare interazioni non lineari complesse tra le feature, particolarmente rilevante in dataset strutturati e ad alta dimensionalità.

5.6 Pseudocodice del framework GRAnD esteso

In questa sezione viene presentato uno pseudocodice ad alto livello del framework GRAnD esteso, che integra i meccanismi di stabilizzazione del training, negative learning ed early stopping basato su convergenza strutturale. Lo pseudocodice ha lo scopo di sintetizzare in modo compatto le principali fasi dell'algoritmo, evidenziandone la natura dinamica e modulare.

Algorithm 1 GRAnD esteso con stabilizzazione e negative learning

Require: Dataset $\mathcal{D} = \{x_i\}_{i=1}^{n}$, modello GRAnD con parametri θ
Require: Iperparametri: m, q, α, configurazioni di warmup e curriculum
Ensure: Parametri ottimizzati $\theta^\star$, soglie stabili u, t_q

Inizializza i parametri del modello θ
Inizializza lo stato delle soglie $\mathcal{T}$ (EVT)
$L \leftarrow \mathcal{D}, \quad U \leftarrow \emptyset, \quad S \leftarrow \emptyset$
for epoca $e = 1, \ldots, E_{\max}$ **do**
    Forward pass e stima dell'energia
    Calcola $E(x)$ per tutti gli $x \in \mathcal{D}$
    Thresholding e partizione del dataset
    Stima le soglie $(u^{(e)}, t_q^{(e)})$ secondo la policy EVT selezionata
    Aggiorna la partizione:

$$L^{(e)} = \{x : E(x) < u^{(e)}\}, \quad U^{(e)} = \{x : u^{(e)} \leq E(x) < t_q^{(e)}\}, \quad S^{(e)} = \{x : E(x) \geq t_q^{(e)}\}$$

    Calcola i pesi $w(x)$ per i campioni $x \in U^{(e)}$
    Aggiornamento dei coefficienti temporali
    Calcola $\lambda_U(e), \lambda_S(e)$ (warmup e ramp)
    Calcola $\lambda_A(e)$ (negative learning)
    Calcola il coefficiente di curriculum $\beta(e)$ sulle soglie
    Ottimizzazione dei parametri
    Aggiorna θ minimizzando:

$$\mathcal{L}_{\text{GRAnD}}^{\text{smooth}} + \lambda_A(e)\, \mathbb{E}_{x \sim S^{(e)} \cup U_{\text{high}}^{(e)}} \left[\|\hat{x} - F(x)\|^2 \right]$$

    dove $\mathcal{L}_{\text{GRAnD}}^{\text{smooth}}$ utilizza una loss a margine liscia
    Verifica della convergenza strutturale
    if le grandezze monitorate risultano stabili su una finestra temporale **then**
        break
    end if
end for
return $\theta^\star$, soglie finali (u, t_q)

Lo pseudocodice evidenzia la natura iterativa e accoppiata del framework GRAnD, in cui la stima delle soglie EVT, la partizione del dataset e l'ottimizzazione del modello si influenzano reciprocamente. Le estensioni introdotte in questo lavoro — stabilizzazione del training, negative learning ed early stopping strutturale — si inseriscono in modo modulare all'interno di questo ciclo, senza modificarne la struttura fondamentale.

Capitolo 6

Valutazione sperimentale e studi di ablation

6.1 Introduzione

In questo capitolo viene presentata una valutazione sperimentale sistematica del framework GRAnD e delle estensioni proposte nel Capitolo 5. Gli esperimenti sono condotti sul dataset NSL-KDD seguendo il protocollo descritto nel Capitolo 4, al fine di garantire la riproducibilità dei risultati e un confronto controllato tra le diverse configurazioni.

La valutazione è strutturata come una sequenza di studi di ablation, in cui ciascun miglioramento viene analizzato isolatamente, mantenendo invariato il resto del framework. Questo approccio consente di attribuire in modo chiaro l'effetto osservato a ciascuna modifica proposta.

Alcune delle estensioni discusse nel Capitolo 5 (warmup e ramp della loss, loss a margine liscia, curriculum learning sulle soglie e variante architetturale ResMLP) sono state validate principalmente dal punto di vista qualitativo e di stabilità del training. Poiché tali modifiche non hanno prodotto variazioni significative delle metriche aggregate nelle configurazioni preliminarmente testate, l'analisi quantitativa dettagliata è stata concentrata sui meccanismi che hanno mostrato un impatto misurabile sulle prestazioni.

6.2 Baseline: GRAnD originale

6.2.1 Replicazione dei risultati del paper

Come primo passo, è stata verificata la capacità di riprodurre i risultati riportati nel paper originale di GRAnD. Per ciascun livello di contaminazione del training set (0%, 5%, 10% e 15%), il modello è stato addestrato utilizzando esclusivamente campioni nominali e valutato sul test set completo.

La Tabella 6.1 riporta i valori di AUROC e AUPRC ottenuti nelle diverse configurazioni. I risultati risultano coerenti con quelli riportati nel lavoro originale, confermando la correttezza dell'implementazione e del protocollo sperimentale adottato.

Tabella 6.1: Prestazioni del framework GRAnD originale sul dataset NSL-KDD per diversi livelli di contaminazione del training set.

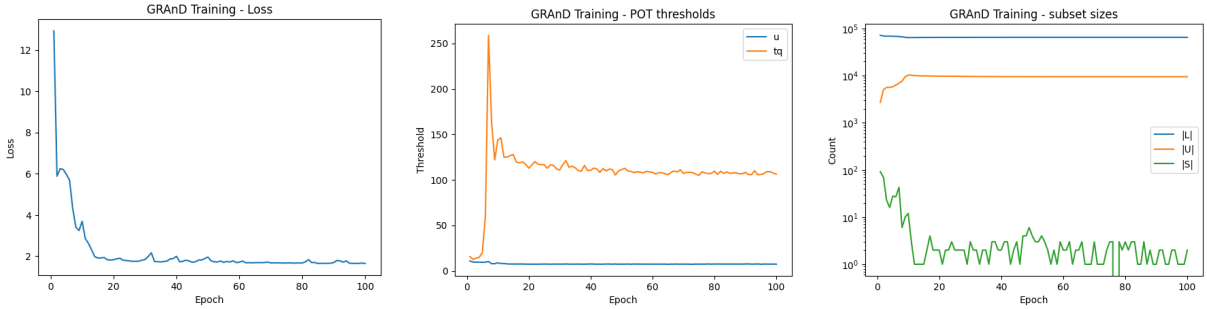
Contaminazione (%)	AUROC	AUPRC
0	0.9361	0.9505
5	0.9389	0.9526
10	0.9382	0.9516
15	0.9222	0.9358

I risultati riportati in Tabella 6.1 risultano coerenti con quelli presentati nel paper originale di GRAnD, confermando la corretta implementazione del modello e del protocollo sperimentale. Si osserva inoltre una moderata degradazione delle prestazioni al crescere del livello di contaminazione, in linea con le aspettative per approcci basati sulla ricostruzione.

6.2.2 Analisi del comportamento durante il training

Oltre alle metriche aggregate, è stata analizzata la dinamica del training del framework GRAnD originale, al fine di comprendere l'evoluzione delle soglie EVT e della partizione del dataset nei sottoinsiemi L, U e S.

La Figura 6.1 mostra l'andamento della loss di training, delle soglie u e t_q, e delle cardinalità degli insiemi L, U e S. Per brevità, nel seguito viene mostrata nel dettaglio la dinamica di training per un livello di contaminazione rappresentativo (10 %). Andamenti analoghi sono stati osservati per gli altri livelli di contaminazione.



(a) Andamento della loss di training.

(b) Evoluzione delle soglie EVT u e t_q.

(c) Cardinalità degli insiemi L, U e S.

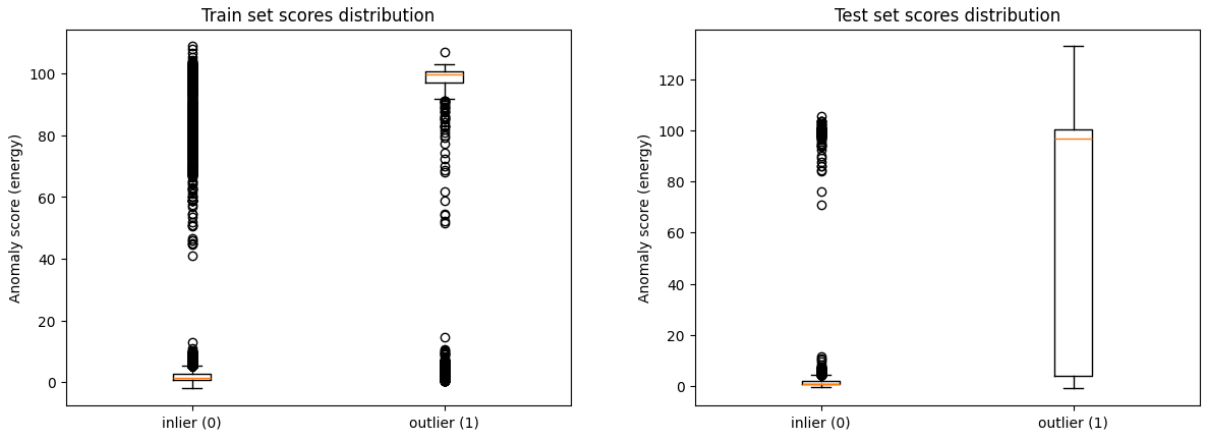
Figura 6.1: Dinamica di training del framework GRAnD originale sul dataset NSL-KDD con livello di contaminazione del training set pari al 10%. Sono mostrati l'andamento della loss, l'evoluzione delle soglie EVT e la stabilizzazione della partizione nei sottoinsiemi L, U e S.

Come mostrato in Figura 6.1, il framework GRAnD originale converge verso una partizione stabile degli insiemi L, U e S. La fase iniziale è caratterizzata da una maggiore variabilità delle soglie EVT, che si attenua progressivamente con il procedere del training.

6.2.3 Prestazioni di detection al variare della contaminazione

Per valutare l'effetto finale della contaminazione sulla capacità di separazione del framework GRAnD originale, vengono analizzate le distribuzioni delle energie nei set di training e di test al

termine dell'addestramento. In particolare, i boxplot consentono di confrontare in modo diretto la separazione tra campioni nominali e anomali nei due contesti.



(a) Distribuzione delle energie nel training set.

(b) Distribuzione delle energie nel test set.

Figura 6.2: Boxplot delle energie per il framework GRAnD originale sul dataset NSL-KDD con livello di contaminazione del training set pari al 10%. Sono mostrate le distribuzioni finali delle energie per campioni nominali e anomali nel training e nel test set.

Come mostrato in Figura 6.2, il framework GRAnD originale riesce a mantenere una separazione significativa tra campioni nominali e anomali nel test set, nonostante la presenza di contaminazione nel training. Tuttavia, nel training set si osserva una parziale sovrapposizione delle distribuzioni energetiche, che aumenta al crescere del livello di contaminazione.

Questo fenomeno suggerisce che, sebbene il modello mantenga buone prestazioni di detection, la contaminazione influisce sulla qualità della modellazione nominale, motivando l'introduzione dei meccanismi di robustezza e stabilizzazione analizzati nelle sezioni successive.

6.3 Ablation su singoli meccanismi di robustezza

In questa sezione vengono analizzati separatamente alcuni dei meccanismi di robustezza introdotti nel Capitolo 5, al fine di valutarne l'impatto isolato sulle prestazioni e sul comportamento del framework GRAnD. L'analisi è limitata ai meccanismi per i quali sono disponibili run sperimentali completi e confrontabili, concentrandosi in particolare su quelli che hanno mostrato un effetto misurabile sul training e sulla stabilità del modello.

6.3.1 Early stopping strutturale

Come discusso nel Capitolo 5, l'early stopping strutturale introduce un criterio di arresto del training basato sulla convergenza congiunta della loss, delle soglie EVT e della partizione del dataset nei sottoinsiemi L, U e S. A differenza di criteri tradizionali basati esclusivamente sull'andamento della loss, questo approccio mira a intercettare uno stato di equilibrio dinamico del framework GRAnD.

L'analisi è stata condotta per diversi livelli di contaminazione del training set, mantenendo invariati tutti gli altri iperparametri.

Dal punto di vista delle metriche di anomaly detection, l'introduzione dell'early stopping strutturale non produce variazioni significative di AUROC e AUPRC rispetto al training a epoche fisse. Questo risultato indica che il criterio di arresto non compromette la qualità della soluzione finale raggiunta dal modello.

Tabella 6.2: Confronto tra GRAnD originale e GRAnD con early stopping strutturale.

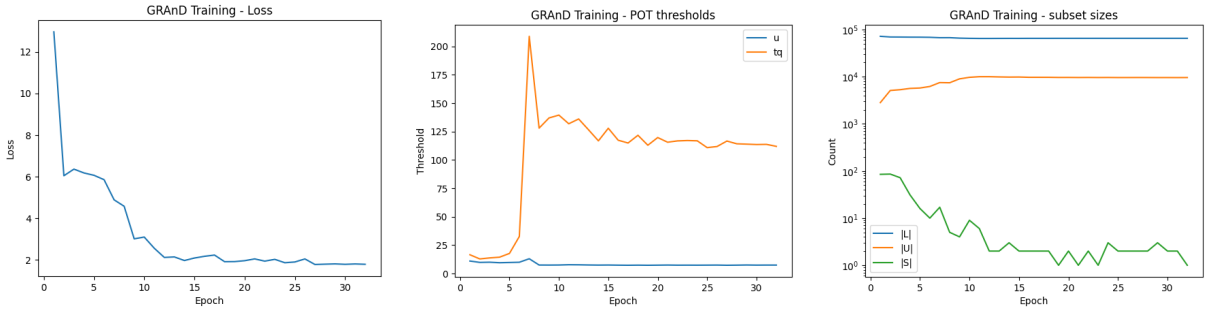
Cont. (%)	**Setup**	**AUROC**	**AUPRC**	**Epoche / Tempo (s)**
0	Originale	0.9361	0.9505	100 / 569.16
	Early stopping	0.9377	0.9518	48 / 321.09
5	Originale	0.9389	0.9526	100 / 603.13
	Early stopping	0.9372	0.9516	31 / 215.04
10	Originale	0.9382	0.9516	100 / 655.14
	Early stopping	0.9394	0.9542	32 / 252.17
15	Originale	0.9222	0.9358	100 / 699.83
	Early stopping	0.9221	0.9356	41 / 299.27

I risultati riportati in Tabella 6.2 mostrano che l'introduzione dell'early stopping strutturale non altera in modo significativo le prestazioni di detection, mantenendo valori di AUROC e AUPRC comparabili a quelli del training a epoche fisse. Al contempo, si osserva una riduzione sostanziale del numero di epoche e del tempo totale di addestramento, con un risparmio computazionale particolarmente marcato ai livelli intermedi di contaminazione.

Questi risultati confermano che l'early stopping strutturale consente di intercettare uno stato di convergenza del framework GRAnD, evitando prolungamenti inutili del training in regime stazionario.

Dal punto di vista dinamico, l'early stopping strutturale consente di interrompere il training non appena le principali grandezze monitorate risultano stabilizzate. In particolare, l'arresto avviene in corrispondenza della convergenza delle soglie u e t_q e della stabilizzazione delle cardinalità normalizzate degli insiemi L, U e S.

Questo comportamento evita prolungamenti inutili del training in regime stazionario, riducendo il rischio di oscillazioni numeriche tardive delle soglie EVT.



(a) Andamento della loss di training.

(b) Evoluzione delle soglie EVT u e t_q.

(c) Cardinalità degli insiemi L, U e S.

Figura 6.3: Dinamica di training del framework GRAnD con early stopping strutturale (contaminazione al 10 %).

6.3.2 Thresholding con cap empirico (POT-cap)

Come discusso nel Capitolo 5, per mitigare l'effetto dell'instabilità di POT, è stata introdotta una variante del thresholding EVT in cui la soglia superiore t_q stimata tramite POT viene limitata superiormente da un quantile empirico della distribuzione delle energie. Formalmente, la soglia utilizzata è definita come:

$$t_q = \min\left(t_q^{\mathrm{POT}},\ Q_{1-q}\right),$$

dove Q_{1-q} rappresenta il quantile empirico di livello $1-q$.

Dal punto di vista dinamico, l'introduzione del cap empirico porta a una maggiore stabilità temporale della soglia t_q, riducendo oscillazioni improvvise e picchi anomali osservabili nel framework originale. Questo effetto si riflette direttamente sulla cardinalità dell'insieme S, che risulta meno soggetta a variazioni brusche tra epoche consecutive.

In particolare, il POT-cap consente di evitare la classificazione prematura di un numero eccessivo di campioni come fortemente anomali nelle fasi iniziali del training, migliorando la robustezza complessiva del meccanismo di filtraggio.



(a) Andamento della loss di training.

(b) Evoluzione delle soglie EVT u e t_q.

(c) Cardinalità degli insiemi L, U e S.

Figura 6.4: Dinamica di training del framework GRAnD con pot_cap (contaminazione al 10 %).

Dal punto di vista delle metriche di detection, l'uso del POT-cap non altera in modo significativo i valori di AUROC e AUPRC rispetto al thresholding EVT originale. Questo risultato indica che la limitazione empirica della soglia non compromette la capacità discriminativa del modello, pur migliorandone la stabilità numerica.

In presenza di livelli più elevati di contaminazione, il POT-cap contribuisce inoltre a ridurre la variabilità inter-run, rendendo il comportamento del framework GRAnD più prevedibile e riproducibile.

Tabella 6.3: Confronto tra thresholding EVT originale e thresholding con cap empirico (POT-cap) per diversi livelli di contaminazione del training set.

Cont. (%)	Setup	AUROC	AUPRC
0	Originale	0.9361	0.9505
	POT-cap	0.9375	0.9507
5	Originale	0.9389	0.9526
	POT-cap	0.9389	0.9527
10	Originale	0.9382	0.9516
	POT-cap	0.9394	0.9530
15	Originale	0.9222	0.9358
	POT-cap	0.9213	0.9369

In sintesi, il thresholding con cap empirico si configura come un meccanismo di robustezza a basso costo, che migliora la stabilità del processo EVT senza introdurre iperparametri aggiuntivi né penalizzare le prestazioni di anomaly detection. Il suo contributo è principalmente di natura numerica e metodologica, rendendolo particolarmente utile in contesti caratterizzati da distribuzioni rumorose delle energie.

6.3.3 Negative learning (AESAD)

Come discusso nel Capitolo 2, il negative learning mira a contrastare l'effetto della contaminazione nel training set penalizzando esplicitamente la ricostruzione dei campioni anomali. Nel framework GRAnD, questo principio è stato integrato adottando una loss ispirata al metodo AESAD, applicata selettivamente ai campioni appartenenti all'insieme S e agli elementi a energia più elevata dell'insieme U.

In questa sottosezione viene analizzato l'effetto isolato del negative learning, confrontando il framework GRAnD originale con una variante in cui la componente AESAD è abilitata (senza warmup+ramp), mantenendo invariati tutti gli altri elementi del training.

Dal punto di vista delle metriche di anomaly detection, l'introduzione del negative learning non altera in modo significativo le metriche aggregate di detection nelle configurazioni testate singolarmente.

Tabella 6.4: Confronto tra GRAnD originale e GRAnD con negative learning (AESAD) per diversi livelli di contaminazione del training set.

Cont. (%)	Setup	AUROC	AUPRC
0	Originale	0.9361	0.9505
	AESAD	0.9372	0.9504
5	Originale	0.9389	0.9526
	AESAD	0.9372	0.9527
10	Originale	0.9382	0.9516
	AESAD	0.9384	0.9517
15	Originale	0.9222	0.9358
	AESAD	0.9214	0.9358

Dal punto di vista della dinamica del training, l'integrazione del negative learning non altera in modo significativo la stabilità del framework GRAnD. La componente AESAD agisce infatti come un termine correttivo locale, limitato a una frazione controllata dei campioni, senza interferire con il meccanismo di thresholding EVT.

Questo aspetto è rilevante in quanto dimostra la compatibilità del negative learning con l'architettura e la funzione obiettivo di GRAnD, rendendo possibile la sua combinazione con altri meccanismi di robustezza.

6.4 Combinazione dei meccanismi di robustezza

Dopo aver analizzato separatamente l'impatto dei singoli meccanismi di robustezza, in questa sezione viene valutato il loro effetto congiunto. In particolare, vengono combinati:

- negative learning basato su AESAD;
- early stopping strutturale;
- thresholding EVT con cap empirico (POT-cap).

L'obiettivo di questa analisi è verificare se i benefici osservati nelle ablation precedenti risultino complementari, producendo un miglioramento complessivo del comportamento del framework GRAnD sia in termini di stabilità che di costo computazionale, senza penalizzare le prestazioni di anomaly detection.

Tabella 6.5: Confronto tra GRAnD originale e GRAnD con combinazione dei meccanismi di robustezza (AESAD + early stopping strutturale + POT-cap) per diversi livelli di contaminazione del training set.

Cont. (%)	**Setup**	**AUROC**	**AUPRC**	**Epoche / Tempo (s)**
0	Originale	0.9361	0.9505	100 / 569.16
	Combinazione	0.9373	0.9517	42 / 257.39
5	Originale	0.9389	0.9526	100 / 603.13
	Combinazione	0.9387	0.9526	61 / 392.90
10	Originale	0.9382	0.9516	100 / 655.14
	Combinazione	0.9355	0.9526	35 / 188.33
15	Originale	0.9222	0.9358	100 / 699.83
	Combinazione	0.9221	0.9372	35 / 187.84

I risultati riportati in Tabella 6.5 mostrano che la combinazione dei meccanismi di robustezza consente di preservare prestazioni di detection comparabili a quelle del framework GRAnD originale per tutti i livelli di contaminazione considerati. Le variazioni osservate nei valori di AUROC e AUPRC risultano contenute e non sistematiche, indicando che l'integrazione dei diversi meccanismi non introduce effetti degradanti sulla capacità discriminativa del modello.

Al contempo, l'impatto sul costo computazionale è significativo. La combinazione dei meccanismi consente una riduzione sostanziale del numero di epoche di training e del tempo totale di addestramento, con risparmi particolarmente evidenti ai livelli di contaminazione medio-alti. Questo risultato conferma la natura complementare dei meccanismi introdotti: l'early stopping

intercetta uno stato di convergenza strutturale, il POT-cap stabilizza il thresholding EVT, mentre il negative learning contribuisce a limitare l'effetto della contaminazione.

Nel complesso, la combinazione dei meccanismi di robustezza proposti consente di rendere il framework GRAnD più stabile, efficiente e riproducibile, senza sacrificare le prestazioni di anomaly detection. Questi risultati motivano l'adozione congiunta delle estensioni proposte in scenari applicativi caratterizzati da dati rumorosi e risorse computazionali limitate.

6.5 Explainability: analisi qualitativa

Oltre alla valutazione quantitativa delle prestazioni di anomaly detection, è stata condotta un'analisi qualitativa volta a valutare l'interpretabilità delle decisioni del framework GRAnD. Poiché lo score di anomalia è definito come energia, risultante dalla combinazione dell'errore di ricostruzione e di un termine latente globale, il modello consente una forma di explainability *by design*, direttamente derivante dalla sua struttura e dalla funzione obiettivo.

In questa sezione viene presentato un esempio rappresentativo di spiegazione locale per un campione classificato come fortemente anomalo nel test set, al fine di illustrare come i diversi contributi allo score energetico possano essere analizzati e interpretati.

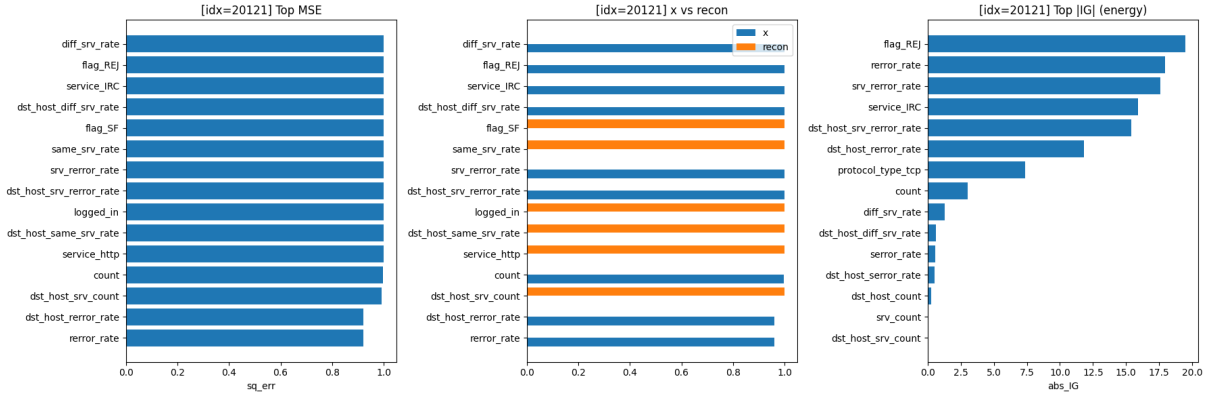


Figura 6.5: Esempio di spiegazione locale per un campione anomalo del test set. (sinistra) feature con maggiore contributo all'errore quadratico di ricostruzione; (centro) confronto tra input e ricostruzione sulle feature più rilevanti; (destra) attribuzioni ottenute tramite Integrated Gradients applicato allo score energetico complessivo.

Come mostrato in Figura 6.5, l'anomalia è caratterizzata da un insieme ristretto di feature che contribuiscono in modo significativo allo score energetico. In particolare, alcune feature presentano un elevato errore di ricostruzione, indicando una scarsa capacità del modello di rappresentare tali pattern come comportamenti nominali. Parallelamente, l'analisi gradient-based basata su Integrated Gradients evidenzia feature che influenzano in modo rilevante lo score energetico complessivo, anche in assenza di un errore di ricostruzione dominante.

Questo risultato mette in evidenza la complementarità tra le due modalità esplicative: la decomposizione per-feature dell'errore di ricostruzione fornisce una spiegazione locale immediata, mentre l'analisi basata sui gradienti consente di interpretare anomalie guidate dal termine latente del modello. Tale combinazione permette di distinguere tra anomalie dovute a mismatch

locali nelle feature osservabili e anomalie riconducibili a incoerenze globali nella rappresentazione latente.

Nel complesso, questa analisi qualitativa conferma che il framework GRAnD, oltre a fornire uno score di anomalia efficace, consente anche una interpretazione delle decisioni del modello senza ricorrere a tecniche post-hoc esterne. Questo aspetto rafforza l'applicabilità del framework in contesti operativi reali, nei quali la comprensione delle cause di un'anomalia risulta spesso altrettanto importante quanto la sua individuazione.

6.6 Discussione complessiva dei risultati

I risultati ottenuti sulla baseline confermano innanzitutto la capacità del framework GRAnD originale di mantenere buone prestazioni di anomaly detection anche in scenari moderatamente contaminati. Tuttavia, l'analisi delle dinamiche di training evidenzia come la stima delle soglie EVT e la partizione degli insiemi L, U e S possano risultare sensibili a instabilità numeriche e a fluttuazioni tardive, in particolare al crescere del livello di contaminazione.

Le ablation sui singoli meccanismi di robustezza mostrano come ciascuna estensione agisca su un aspetto specifico del framework. L'early stopping strutturale consente di intercettare uno stato di convergenza dinamica del modello, riducendo in modo significativo il costo computazionale senza alterare le prestazioni di detection. Il thresholding con cap empirico (POT-cap) migliora la stabilità numerica della soglia superiore t_q, limitando oscillazioni spurie dovute alla stima dei parametri EVT. Il negative learning basato su AESAD, pur non producendo miglioramenti sostanziali sulle metriche aggregate quando considerato isolatamente, contribuisce a contrastare l'effetto di over-generalization in presenza di contaminazione.

Un aspetto rilevante emerso dall'analisi sperimentale è che i benefici dei diversi meccanismi non si manifestano in modo indipendente, ma risultano fortemente complementari. La combinazione di early stopping strutturale, POT-cap e negative learning consente infatti di ottenere un framework complessivamente più stabile ed efficiente, preservando prestazioni di anomaly detection comparabili a quelle del modello originale, ma con un costo computazionale sensibilmente ridotto.

Questi risultati suggeriscono che, nel contesto dell'anomaly detection non supervisionata, il miglioramento delle prestazioni non debba necessariamente tradursi in un incremento delle metriche aggregate, ma possa emergere sotto forma di maggiore robustezza, stabilità e riproducibilità del processo di training. In particolare, la riduzione della sensibilità alla contaminazione e l'eliminazione di dinamiche instabili rendono il framework più adatto a scenari applicativi reali, caratterizzati da dati rumorosi e da risorse computazionali limitate.

Nel complesso, l'analisi sperimentale conferma la validità delle estensioni proposte e ne evidenzia il ruolo principalmente metodologico e pratico, più che puramente prestazionale. Il framework GRAnD esteso emerge così come una soluzione flessibile e robusta per l'anomaly detection, in cui la stabilità del training e l'efficienza computazionale assumono un ruolo centrale accanto alla capacità discriminativa.

Capitolo 7

Conclusioni e sviluppi futuri

In questo lavoro è stato analizzato e approfondito il framework GRAnD per l'anomaly detection non supervisionata, con particolare attenzione alla sua robustezza in presenza di contaminazione del training set. Dopo aver replicato i risultati del paper originale sul dataset NSL-KDD, sono state proposte e investigate diverse estensioni metodologiche volte a migliorare la stabilità, l'efficienza e l'affidabilità del processo di training.

Il contributo principale di questo lavoro risiede nell'analisi sistematica dei meccanismi che governano la dinamica interna di GRAnD. In particolare, è stato mostrato come il comportamento del framework non dipenda unicamente dalla funzione obiettivo, ma emerga dall'interazione tra modello generativo, thresholding basato su Extreme Value Theory e partizione dinamica del dataset nei sottoinsiemi L, U e S. Questa osservazione ha motivato l'introduzione di meccanismi di robustezza mirati a stabilizzare tali interazioni.

Dal punto di vista sperimentale, i risultati ottenuti mostrano che le estensioni proposte non mirano tanto a massimizzare le metriche aggregate di anomaly detection, quanto a rendere il framework più stabile ed efficiente. L'early stopping strutturale consente di ridurre significativamente il costo computazionale intercettando uno stato di convergenza dinamica del modello. Il thresholding con cap empirico migliora la stabilità numerica delle soglie EVT, mentre il negative learning basato su AESAD contribuisce a limitare l'effetto di over-generalization indotto dalla contaminazione. La combinazione di questi meccanismi produce un framework complessivamente più robusto, senza penalizzare le prestazioni di detection.

Un aspetto rilevante emerso da questo studio è che, in contesti di anomaly detection non supervisionata, il miglioramento del modello non deve necessariamente riflettersi in incrementi significativi delle metriche di valutazione. In scenari applicativi reali, la stabilità del training, la riproducibilità dei risultati e l'efficienza computazionale rappresentano criteri altrettanto cruciali quanto la capacità discriminativa. In questo senso, le estensioni proposte rendono GRAnD più adatto a essere utilizzato in ambienti operativi caratterizzati da dati rumorosi e risorse limitate.

Per quanto riguarda gli sviluppi futuri, diverse direzioni di ricerca risultano di particolare interesse. Una prima possibile estensione riguarda l'applicazione del framework GRAnD esteso a dataset differenti, in particolare in ambiti industriali o cyber-fisici, al fine di valutarne la generalità e la trasferibilità. Un'ulteriore direzione consiste nell'esplorare architetture generative più complesse, mantenendo invariata la dinamica di thresholding EVT. Infine, l'integrazione

di meccanismi di explainability più avanzati potrebbe consentire una comprensione ancora più approfondita delle anomalie rilevate, facilitandone l'interpretazione in contesti applicativi reali.

Nel complesso, questo lavoro dimostra come un'analisi attenta della dinamica di training e dei meccanismi di robustezza possa contribuire in modo significativo al miglioramento pratico dei sistemi di anomaly detection non supervisionata, aprendo la strada a ulteriori sviluppi sia teorici che applicativi.

Bibliografia

[1] Hamed Akrami, Anand A. Joshi, Jingwan Li, Sertac Aydore, and Richard M. Leahy. Robust variational autoencoder. *arXiv preprint arXiv:2006.05980*, 2020.

[2] Fabrizio Angiulli, Fabio Fassetti, and Luca Ferragina. Reconstruction error-based anomaly detection with few outlying examples. *arXiv preprint arXiv:2305.10464*, 2023.

[3] Naji Najari, Samuel Berlemont, Grégoire Lefebvre, Stefan Duffner, and Christophe Garcia. Robust variational autoencoders and normalizing flows for unsupervised network anomaly detection. In *Proceedings of the International Conference on Advanced Information Networking and Applications (AINA)*, 2022.

[4] Alban Siffer, Pierre-Alain Fouque, Alexandre Termier, and Christine Largouet. Anomaly detection in streams with extreme value theory. In *Proceedings of KDD*, 2017.

[5] Chong Zhou and Randy C. Paffenroth. Anomaly detection with robust deep autoencoders. In *Proceedings of KDD*, 2017.

[6] Bo Zong, Qi Song, M. Renqiang Min, Wei Cheng, Cristian Lumezanu, Daeki Cho, and Haifeng Chen. Deep autoencoding gaussian mixture model for unsupervised anomaly detection. In *International Conference on Learning Representations*, 2018.