GRAnD-NL

Anomaly Detection Non Supervisionata tramite Negative Learning e Stabilizzazione Dinamica

Davide Cinelli

Università della Calabria
Corso di Laurea Magistrale in Ingegneria Informatica

Anno Accademico 2025/2026

L'Unsupervised Anomaly Detection e la Sfida della Contaminazione

- **Task:** Identificare campioni rari (Outliers) che deviano dal comportamento normale (Inliers) in modo non supervisionato.
- **Il Problema della Contaminazione:** In contesti reali (es. cybersecurity), il training set contiene già attacchi non etichettati.
- **Deep Overfitting:** I modelli ad alta capacità tendono a minimizzare l'errore anche sulle anomalie presenti nel training set, rendendole indistinguibili.

Obiettivo

Sviluppare un framework robusto capace di isolare e "respingere" i campioni contaminanti durante il processo di apprendimento.

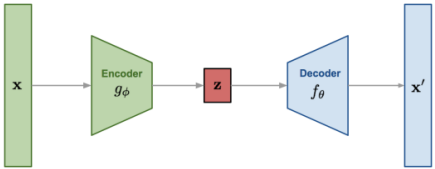
Baseline: Autoencoder e Reconstruction Score

- **Architettura:** Encoder ψ e Decoder ϕ.
- **Meccanismo:** Compressione in uno spazio latente z e ricostruzione $\hat{x}$.
- **Score di Anomalia:**

$$S(x) = \|x - \phi(\psi(x))\|^2$$

Limite

Sensibile alla contaminazione nel training set e privo di interpretazione probabilistica.



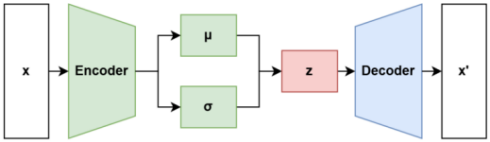
Background Generativo: VAE e Normalizing Flows

Variational Autoencoder (VAE)

- Modello generativo probabilistico.
- Regolarizzazione dello spazio latente tramite KL divergence.

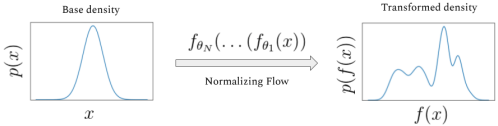
$$\mathcal{L}_{VAE} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x)\|p(z))$$

$$\mathcal{F}(x) = -\text{ELBO}(x)$$



Normalizing Flows

- Posterior più espressivo.
- Trasformazioni invertibili con Jacobiano noto.

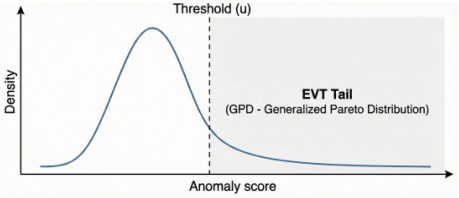


Energy Score GRAnD: combinazione di errore di ricostruzione e densità probabilistica.

Extreme Value Theory (EVT) e soglia POT

- **Peaks-Over-Threshold (POT):** modellazione della sola coda degli score estremi.
- **Generalized Pareto Distribution (GPD):** gli eccessi oltre una soglia u seguono una GPD:

$$G(y;\sigma,\xi) = 1 - \left(1 + \frac{\xi y}{\sigma}\right)^{-1/\xi}$$



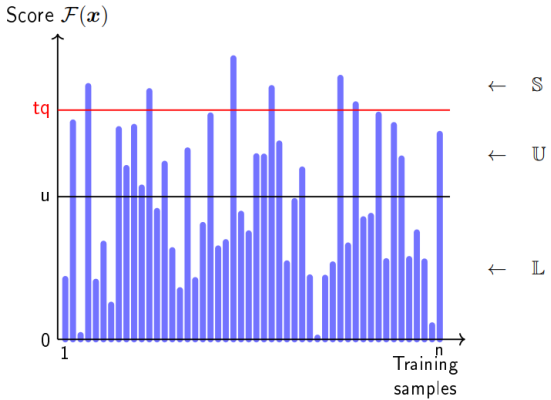
Risultato

La soglia estrema t_q viene stimata in modo adattivo durante il training.

II Framework GRAnD: Rejection Split L/U/S

Il training set viene partizionato dinamicamente usando l'energia $F(x)$:

- **Inliers (L):** $F(x) < u$
- **Unlabeled (U):** $u \leq F(x) < t_q$
- **Suspects (S):** $F(x) \geq t_q$



Il Framework GRAnD: Funzione obiettivo

La strategia di training combina tre obiettivi distinti sui sottoinsiemi L, U e S:

$$\mathcal{L}_{\text{GRAnD}} = \mathbb{E}_{x\sim L}[F(x)] + |m - \mathbb{E}_{x\sim S}[F(x)]| + w(x)\,|m - \mathbb{E}_{x\sim U}[F(x)]|$$

$w(x) = \text{eCDF}(F(x)) \in [0,1]$ (più vicino a $t_q \Rightarrow$ più "anomalo").

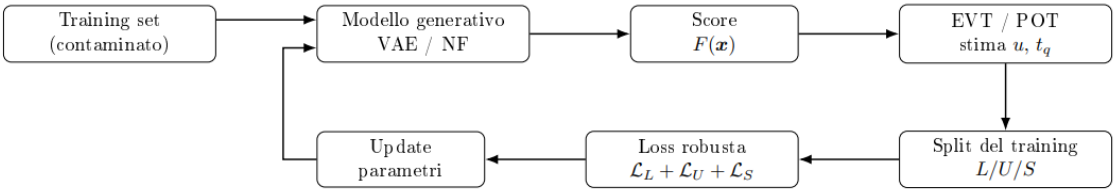
- **Inliers (L):** minimizzazione dell'energia (apprendimento del comportamento normale).
- **Suspects (S):** massimizzazione controllata dell'energia tramite margine m.
- **Unlabeled (U):** contributo pesato tramite eCDF, che riflette il grado di incertezza.

Idea chiave

GRAnD sfrutta esplicitamente le anomalie individuate nel training per imparare una rappresentazione più robusta.

Il Framework GRAnD: Pipeline di Addestramento

1. Calcolo dell'energy score $F(x)$.
2. Stima delle soglie u e t_q tramite EVT (POT).
3. Suddivisione del dataset in L, U, S.
4. Aggiornamento del modello con loss GRAnD.
5. Iterazione fino a convergenza.



Dataset: NSL-KDD

Struttura del Dataset

- Benchmark standard per intrusion detection.
- 41 feature di traffico di rete.
- Feature eterogenee:
  - continue (durata, byte, conteggi)
  - categoriche (protocollo, servizio, flag)

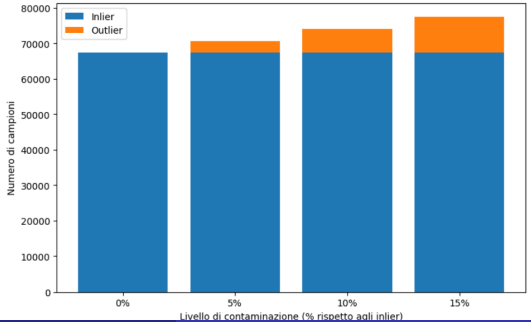
F#	Feature name	F#	Feature name	F#	Feature name
F1	Duration	F15	Su attempted	F29	Same srv rate
F2	Protocol type	F16	Num root	F30	Diff srv rate
F3	Service	F17	Num file creations	F31	Srv diff host rate
F4	Flag	F18	Num shells	F32	Dst host count
F5	Source bytes	F19	Num access files	F33	Dst host srv count
F6	Destination bytes	F20	Num outbound cmds	F34	Dst host same srv rate
F7	Land	F21	Is host login	F35	Dst host diff srv rate
F8	Wrong fragment	F22	Is guest login	F36	Dst host same src port rate
F9	Urgent	F23	Count	F37	Dst host srv diff host rate
F10	Hot	F24	Srv count	F38	Dst host serror rate
F11	Number failed logins	F25	Serror rate	F39	Dst host srv serror rate
F12	Logged in	F26	Srv serror rate	F40	Dst host rerror rate
F13	Num compromised	F27	Rerror rate	F41	Dst host srv rerror rate
F14	Root shell	F28	Srv rerror rate	F42	Class label

Scenario di Contaminazione

- Il training set non è anomaly-free.
- Iniezione controllata di attacchi nel training:

$$\gamma \in \{0\%, 5\%, 10\%, 15\%\}$$

- Il contamination ratio è **ignoto** al modello.



Il Framework GRAnD: Replica Sperimentale

- Valutazione su NSL-KDD con contaminazione nel training (da 0% a 15%).
- Metriche: AUROC e AUPRC.
- Performance stabili anche al crescere della contaminazione.

Contaminazione (%)	AUROC	AUPRC
0	0.9361	0.9505
5	0.9389	0.9526
10	0.9382	0.9516
15	0.9222	0.9358

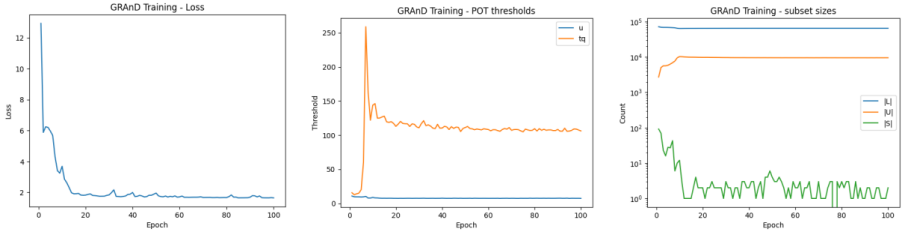
Nota

I risultati mostrati derivano da una replica sperimentale indipendente del framework GRAnD.

Il framework GRAnD: Limitazioni

Perché estendere GRAnD? Il metodo originale è concettualmente solido, ma:

- Training potenzialmente lungo e instabile (oscillazioni di u e t_q, insiemi poco significativi).
- Assenza di criteri di arresto robusti.
- Nessuna interpretabilità integrata delle decisioni di anomalia.



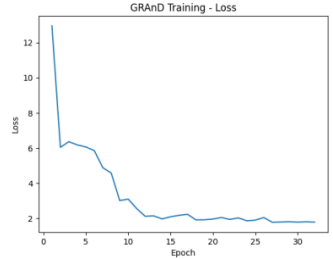
Obiettivo delle estensioni

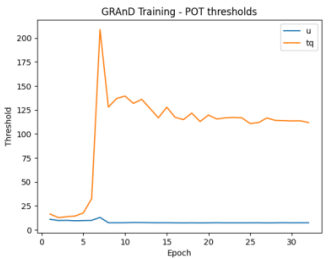
Migliorare **stabilità**, **efficienza** e **interpretabilità** senza alterare il principio teorico di GRAnD.

Early Stopping basato su stabilità strutturale

- Early stopping classico (loss-only) inadeguato in presenza di POT dinamico.
- Proposta: arresto quando diventano stabili:
  - loss media
  - soglie EVT (u, t_q)
  - cardinalità dei sottoinsiemi $|L|, |U|, |S|$
- Criterio valutato su una finestra temporale (Window Early Stopping).

Cont. (%)	Setup	AUROC	AUPRC	Epoche / Tempo (s)
0	Originale	0.9361	0.9505	100 / 569.16
	Early stopping	0.9377	0.9518	48 / 321.09
5	Originale	0.9389	0.9526	100 / 603.13
	Early stopping	0.9372	0.9516	31 / 215.04
10	Originale	0.9382	0.9516	100 / 655.14
	Early stopping	0.9394	0.9542	32 / 252.17
15	Originale	0.9222	0.9358	100 / 699.83
	Early stopping	0.9221	0.9356	41 / 299.27







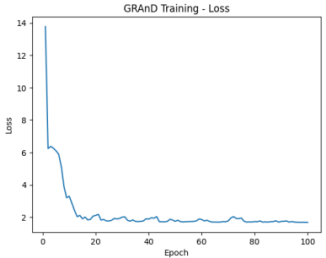
Stabilizzazione EVT: POT_CAP

- In GRAnD, t_q^{POT} (fit GPD), può risultare instabile (fit difficile, poche exceedances, spike).
- **Idea POT_CAP:** limitare la soglia POT tramite il quantile empirico:

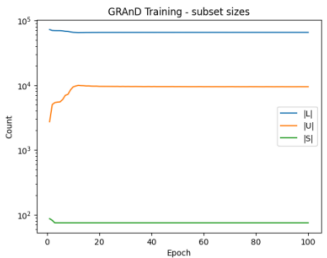
$$t_q = \min\left(t_q^{POT},\ t_q^{emp}\right), \qquad t_q^{emp} = Q_{1-q}(F)$$

- Effetto: split $L/U/S$ più stabile e training meno sensibile agli outlier estremi.

Cont. (%)	Setup	AUROC	AUPRC
0	Originale	0.9361	0.9505
	POT-cap	0.9375	0.9507
5	Originale	0.9389	0.9526
	POT-cap	0.9389	0.9527
10	Originale	0.9382	0.9516
	POT-cap	0.9394	0.9530
15	Originale	0.9222	0.9358
	POT-cap	0.9213	0.9369







AESAD: Negative Learning per Robust Anomaly Detection

- AESAD introduce **negative learning esplicito**:
  - **Positive learning**: minimizzare l'errore su campioni nominali.
  - **Negative learning**: massimizzare l'errore su campioni negativi.
- Negativi generati tramite *corruption* (feature swapping, perturbazioni).
- Obiettivo: aumentare la separabilità tramite una forza repulsiva nel training.

Cont. (%)	Setup	AUROC	AUPRC
0	Originale	0.9361	0.9505
	AESAD	0.9372	0.9504
5	Originale	0.9389	0.9526
	AESAD	0.9372	0.9527
10	Originale	0.9382	0.9516
	AESAD	0.9384	0.9517
15	Originale	0.9222	0.9358
	AESAD	0.9214	0.9358

$$\mathcal{L}_F(x) = (1-y)\,\|x-\hat{x}\|^2 + \lambda\, y\,\|F(x)-\hat{x}\|^2, \qquad y \in \{0,1\}$$

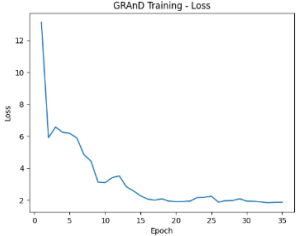
dove $y = 1$ per $x \in S \cup U_{\text{top}}$, e $y = 0$ altrimenti.

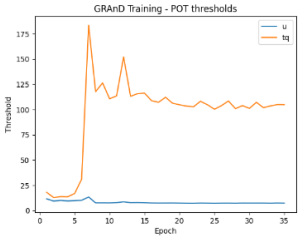
GRAnD-NL: perché la combinazione funziona meglio

- Le tre estensioni agiscono su **aspetti complementari** del framework:
  - **Early Stopping (ES):** migliora la stabilità e l'efficienza del training, evitando overfitting e oscillazioni tardive.
  - `POT_CAP`**:** stabilizza la stima delle soglie EVT, riducendo spike e split $L/U/S$ patologici.
  - **AESAD (Negative Learning):** rafforza la separazione tra normali e anomalie introducendo una forza repulsiva esplicita.
- **Combinazione finale:** GRAnD-NL integra i tre moduli senza modificare il backbone originale, ma migliorandone:
  - robustezza,
  - stabilità,
  - capacità di separazione.
- I risultati sperimentali mostrano che la combinazione supera l'effetto delle singole estensioni considerate isolatamente.

GRAnD-NL: Metriche e Dinamica di Training

Cont. (%)	Setup	AUROC	AUPRC	Epoche / Tempo (s)
0	Originale	0.9361	0.9505	100 / 569.16
	Combinazione	0.9373	0.9517	42 / 257.39
5	Originale	0.9389	0.9526	100 / 603.13
	Combinazione	0.9387	0.9526	61 / 392.90
10	Originale	0.9382	0.9516	100 / 655.14
	Combinazione	0.9355	0.9526	35 / 188.33
15	Originale	0.9222	0.9358	100 / 699.83
	Combinazione	0.9221	0.9372	35 / 187.84







Altre estensioni esplorate (non riportate nei risultati)

Oltre alla combinazione finale, sono state investigate ulteriori modifiche per migliorare stabilità e robustezza del training.

- **Smoothing della loss:** sostituzione di termini con valore assoluto con varianti smooth (es. Softplus) per stabilizzare gradienti e ridurre spike.
- **Curriculum su t_q:** attivazione progressiva del thresholding estremo (inizialmente t_q più conservativo, poi verso il target).
- **Strategie alternative di thresholding:** varianti per stimare (u, t_q) (quantili doppi, fit robusti, EMA delle soglie).
- **Warmup & ramp:** schedulazione dei contributi di S e/o U e del termine AESAD per ridurre instabilità nelle epoche iniziali.
- **Variante architetturale (GRAnD-ResMLP):** sostituzione della backbone MLP con blocchi residuali (ResMLP) per aumentare capacità e stabilità del training su input ad alta dimensionalità.

Nota

I risultati non sono inclusi per brevità: le modifiche sono riportate come analisi esplorative/ablation.

GRAnD-NL: Pseudocodice

Algorithm 1 GRAnD esteso con stabilizzazione e negative learning

Require: Dataset $\mathcal{D} = \{x_i\}_{i=1}^{n}$, modello GRAnD con parametri θ
Require: Iperparametri: m, q, α, configurazioni di warmup e curriculum
Ensure: Parametri ottimizzati $\theta^{\star}$, soglie stabili u, t_q

Inizializza i parametri del modello θ
Inizializza lo stato delle soglie $\mathcal{T}$ (EVT)
$L \leftarrow \mathcal{D}, \quad U \leftarrow \emptyset, \quad S \leftarrow \emptyset$
for epoca $e = 1, \ldots, E_{\max}$ **do**
    Forward pass e stima dell'energia
    Calcola $E(x)$ per tutti gli $x \in \mathcal{D}$
    Thresholding e partizione del dataset
    Stima le soglie $(u^{(e)}, t_q^{(e)})$ secondo la policy EVT selezionata
    Aggiorna la partizione:

$$L^{(e)} = \{x : E(x) < u^{(e)}\}, \quad U^{(e)} = \{x : u^{(e)} \le E(x) < t_q^{(e)}\}, \quad S^{(e)} = \{x : E(x) \ge t_q^{(e)}\}$$

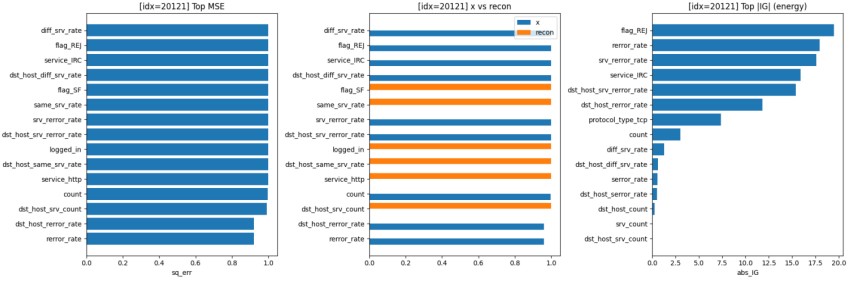
    Calcola i pesi $w(x)$ per i campioni $x \in U^{(e)}$
    Aggiornamento dei coefficienti temporali
    Calcola $\lambda_U(e), \lambda_S(e)$ (warmup e ramp)
    Calcola $\lambda_A(e)$ (negative learning)
    Calcola il coefficiente di curriculum $\beta(e)$ sulle soglie
    Ottimizzazione dei parametri
    Aggiorna θ minimizzando:

$$\mathcal{L}_{\text{GRAnD}}^{\text{smooth}} + \lambda_A(e)\, \mathbb{E}_{x \sim S^{(e)} \cup U_{\text{high}}^{(e)}} \left[\|\hat{x} - F(x)\|^2 \right]$$

    dove $\mathcal{L}_{\text{GRAnD}}^{\text{smooth}}$ utilizza una loss a margine liscia
    Verifica della convergenza strutturale
    if le grandezze monitorate risultano stabili su una finestra temporale **then**
        break
    end if
end for
return $\theta^{\star}$, soglie finali (u, t_q)

Explainability: interpretazione delle anomalie

- In contesti reali (es. cybersecurity) non è sufficiente segnalare un'anomalia: è necessario **capire il perché**, per supporto all'analisi forense e maggiore fiducia nel modello.
- Analisi a livello di feature per campioni classificati come anomali.
- Metodi utilizzati:
  - decomposizione dell'errore di ricostruzione (MSE per feature),
  - gradient-based attribution sullo score energetico.
- Output: **ranking delle feature** che contribuiscono maggiormente all'alta energia.



Conclusioni e Sviluppi Futuri

Conclusioni

- GRAnD affronta l'anomaly detection non supervisionata in presenza di contaminazione nel training set.
- La replica su NSL-KDD conferma la robustezza del metodo al crescere della contaminazione.
- Le estensioni proposte (**ES** + **POT_CAP** + **AESAD**) migliorano:
  - stabilità del training,
  - efficienza computazionale,
  - separazione tra normali e anomalie.
- Il framework finale **GRAnD-NL** mantiene il backbone originale, rendendolo più affidabile.

Sviluppi Futuri

- Valutazione su dataset reali e più complessi (traffico di rete reale, time series).
- Selezione adattiva dei negativi (hard negative mining in U).
- Modelli generativi più espressivi (Normalizing Flows più profondi).
- Explainability avanzata a livello di flusso e temporale.
- Ottimizzazione automatica degli iperparametri in presenza di contaminazione.

Grazie per l'attenzione